

PSPP 入门教程

目录

Table of Contents	2
前言	2
编写说明	2
读者对象	2
本书特点	2
章节安排	3
符号与约定	3
致谢与免责声明	3
1.1 什么是 PSPP	3
1.2 PSPP 的发展与开源背景	4
1.3 PSPP 与 SPSS 的关系及异同	4
1.4 PSPP 的功能特点与适用场景	4
1.5 本书约定与符号说明	5
2.1 系统需求	5
2.2 在 Windows 上安装 PSPP	5
2.3 在 macOS 上安装 PSPP	6
2.4 在 Linux 上安装 PSPP	6
2.5 首次启动与界面初识	6
2.6 语言与区域设置	7
3.1 数据集与变量基础概念	7
3.2 新建数据文件与变量定义	8
3.3 数据录入与编辑	8
3.4 从外部文件导入数据	9
3.5 变量属性的深入设置	10
3.6 数据整理：排序、拆分文件、选择个案	10
3.7 变量计算与重新编码	11
3.8 数据清洗与缺失值处理	11
4.1 描述性统计的意义	12
4.2 频率分析	13
4.3 描述统计	13
4.4 交叉表分析	14
4.5 探索性数据分析	15
5.1 统计推断与假设检验的基本思想	15
5.2 显著性水平与第一、二类错误	16
5.3 单样本 t 检验	16
5.4 独立样本 t 检验	17
5.5 配对样本 t 检验	17
5.6 非参数检验入门	18
6.1 方差分析的基本思想	19
6.2 单因素方差分析	19
6.3 双因素方差分析	20
6.4 方差齐性检验	21
6.5 多重比较与事后检验	21
7.1 相关分析与回归分析的关系定位	22
7.2 相关分析 CORRELATIONS	22
7.3 简单线性回归 REGRESSION	24

7.4 多元回归与模型解读	24
7.5 回归诊断与限制	25
8.1 图表命令总览	26
8.2 散点图 GRAPH /SCATTERPLOT	27
8.3 直方图 GRAPH /HISTOGRAM	27
8.4 条形图 GRAPH /BAR	28
8.5 其他图表路径	29
8.6 限制与导出	30
附录 A ·PSPP 命令速查表	31
PSPP 当前未实现的过程	33
附录 B ·常用统计术语中英对照	33
附录 C ·练习数据与素材说明	34
附录 D ·进阶学习资源	34

Table of Contents

%

% 2026 年 8 月

前言

编写说明

GNU PSPP 是一套自由软件，定位为 SPSS 统计产品语法与部分功能的开源替代。本书以 PSPP 2.0.1 版本为基础撰写，所有命令、语法与界面描述均锚定该版本的官方手册与真实软件行为，力求与后续各章口径保持一致。

写作的初衷，源于统计初学者在接触 PSPP 时常常面对两份落差：一份是零散、以英文术语为主的官方文档，另一份是论坛里真假难辨的操作经验。本书试图在二者之间搭一座桥——用中文把最常用的分析流程讲清楚，同时把“手册里写明了什么”与“界面上能推断什么”分开标注，避免读者把通用统计软件的界面习惯误当成 PSPP 的确定能力。

内容组织遵循由数据到结论的递进：先建立变量与数据集的概念，再依次展开描述统计、假设检验、方差分析与回归，最后落到图表呈现。每一章都配备可在 PSPP 中直接运行的示例，使读者在动手过程中建立判断，而非停留在概念层面。

读者对象

本书面向统计学初学者，以及第一次接触 PSPP 或 SPSS 类软件的研究者。无论你来自社会学、医学、教育学还是市场研究，只要工作中需要把问卷、实验记录或观测数据转化为可靠的定量结论，都能从中获益。

我们假定读者具备基础的统计常识，例如知道均值与标准差各自描述什么，但不需要事先掌握任何命令行工具。图形界面下的每一步操作都会给出对应的语法，便于日后把分析迁移到批处理脚本，也方便在服务器等无界面环境中复用。

本书特点

由浅入深。前几章只依赖最少的统计背景，随篇幅推进逐步引入检验与模型，使不同起点的读者都能跟上节奏。

以真实软件行为为准。书中的命令均经过 PSPP 2.0.1 实测或出自官方手册，不照搬其他软件的过期经验，也不渲染未经证实的功能。

示例驱动。每个核心过程都配有数据构想、操作步骤与结果解读，而非孤立地罗列语法，读者可边读边练。

区分两种知识来源。凡手册明确记载的菜单与对话框，标以【手册明示】；凡依据 PSPPIRE 或 SPSS 通用界面结构推断、手册未逐项文档化的，标以【界面推断】，并说明其性质，提醒读者以实际软件为准。

如实说明功能边界。PSPP 并非 SPSS 的完整克隆，部分过程尚未实现，本书会在相应位置明确指出，而非含糊带过，帮助读者在遇到限制时及时转向可行路径。

章节安排

全书共八章，另设一个附录。第一章介绍 PSPP 的定位、两种运行界面与开源许可，帮助读者建立整体认知；第二章讲解安装、启动与基础配置，并提示区域设置对数据录入的影响；第三章进入数据管理，覆盖变量定义、数据录入、从 Excel 与 CSV 导入、排序、拆分、筛选，以及变量的计算与重编码；第四章至第五章是统计核心，分别处理描述性统计与假设检验，含 t 检验与非参数方法；第六章讨论方差分析，单因素走 ONEWAY，双因素及以上须改用 GLM；第七章介绍相关与回归分析；第八章聚焦图表，说明散点图、直方图、条形图与箱线图的实现方式及其限制。附录提供命令到菜单路径的速查映射，方便在语法与界面之间对照查阅。

各章内容一览：

- 第一章 PSPP 概述
- 第二章 安装与配置
- 第三章 数据管理
- 第四章 描述性统计
- 第五章 假设检验
- 第六章 方差分析
- 第七章 回归分析
- 第八章 图表
- 附录 命令—菜单速查映射

符号与约定

PSPP 命令、子命令、变量名、文件扩展名及英文菜单项均保持英文原样，例如 COMPUTE、/VARIABLES、psppire、.sav，其后的中文为说明文字。

代码块内的语法为可在 PSPP 中运行的语句，以英文句点结尾；在 data> 提示符下交互录入时，不要再重复输入这个句点。

凡标注【界面推断】者，表示该项依据通用图形界面知识给出，PSPP 手册未逐项文档化，使用时请以实际软件中的表现为准。

统计符号采用通行约定：显著性水平记为 α ，概率值记为 p ，样本均值记为 $\bar{x}$ ，样本标准差记为 s 。其余统计量在正文中首次出现时一并给出说明，避免读者来回翻查。

致谢与免责声明

本书示例所用数据均为虚构，仅用于演示操作步骤，不得用于任何真实研究或论文结论。

GNU PSPP 程序本身以 GNU GPL 许可发布，文档以 GFDL 许可发布；本书的中文整理与表述在遵循上述许可的前提下供学习参考。

PSPP 仍在持续演进，手册原文亦自陈其为“a work in progress”。对于重要的分析任务，请以官方手册与你的专业判断为准；本书不对依据示例得出的具体结论承担责任。# 第一章 PSPP 概述

1.1 什么是 PSPP

PSPP 是一套自由、开源的统计分析与报表生成程序，由 GNU 项目维护。它的设计目标，是提供一套与 SPSS 这类商业统计产品句法相近、却完全不受专有许可约束的分析工具——既能在图形界面里点选完成常规分析，也能通过纯文本命令写出可复现的批处理脚本。

PSPP 以两种形态交付，二者共享同一套计算内核：

- pspp：命令行界面（文本界面）。分析者把命令写入语法文件，再以 pspp file.sps 的方式批量运行，或者进入交互提示符逐条键入。
- psppire：图形用户界面（Graphical User Interface，PSPPIRE）。它提供数据编辑器、语法编辑器与输出查看器，使不熟悉命令的分析者也能通过菜单完成操作。

在 pspp 命令行界面中，既可以把分析写成语法文件后批量运行：

```
$ pspp analysis.sps
```

也可以进入交互提示符逐条键入（每行一条命令，以英文句点结尾）：

```
PSPP> DESCRIPTIVES /VARIABLES=height.
```

而在 psppire 图形界面下，同样的分析可在语法编辑器里输入 `DESCRIPTIVES /VARIABLES=height.` 后，通过 Run 菜单运行【手册明示】。

需要强调：PSPP 的语法与 SPSS 的语法“相似”（similar to SPSS statistical products），而非逐字兼容。大部分常用命令、子命令的写法彼此相通，但在细节与过程覆盖面上存在差别，这一点将在 1.3 节展开。分析结果可输出为多种格式，包括 ASCII、PostScript、PDF、HTML、DocBook 与 TeX，便于直接嵌入论文、网页或排版系统。

1.2 PSPP 的发展与开源背景

PSPP 诞生于自由软件运动的脉络之中。它隶属于 GNU 项目，践行“自由软件”（free software）的理念：用户不仅免费获得程序，更享有运行、研究、再分发与改进它的四项核心自由。这一理念决定了 PSPP 与商业统计软件在授权上的根本不同——后者的能力被密封在许可证条款之内，而 PSPP 的全部权利从一开始就交还给使用者。

程序本身以 GNU 通用公共许可证（GNU GPL）发布；随附文档则以 GNU 自由文档许可证（GFDL，GNU Free Documentation License）发布。换言之，你运行的每一行可执行代码与阅读的每一份手册文字，其许可都是公开、可核查的，而非包裹在最终用户许可协议（EULA）的封闭条款里。这种许可结构使本书得以在遵循原许可的前提下进行中文整理与表述。

自由软件并不意味着“已经做完”。PSPP 官方手册原话即坦言：“PSPP is a work in progress.”（PSPP 仍是一项进行中的工作。）这句话不是谦辞，而是对软件状态的如实陈述：它持续改进，亦有尚未补齐的环节。读者在依赖 PSPP 完成关键分析时，应参照官方手册与自身专业判断，而非假定它已与某一商业产品完全对等。

1.3 PSPP 与 SPSS 的关系及异同

把 PSPP 理解为“SPSS 的开源克隆”是一个常见的误会。两者确实渊源深厚：PSPP 的许多命令名、子命令结构乃至数据文件格式（.sav）都刻意贴近 SPSS，使习惯 SPSS 的分析者能平滑迁移。语法层面的“相似”是真实的，也是 PSPP 最有价值的特性之一。

然而相似不等于完整兼容，二者之间存在清晰边界。其一，PSPP 并未实现 SPSS 的全部过程，尤其是一批高级统计与作图功能目前缺失（详见 1.4 节与附录）。其二，PSPP 解读语法时遵循自己的实现，某些在 SPSS 中可行的写法未必被 PSPP 接受，反过来 PSPP 的扩展也未必能在 SPSS 中运行。其三，图形界面 PSPPIRE 的菜单布局参照了通用统计软件习惯，但并未逐一复刻 SPSS 的每一个对话框，相关路径在本书中均标注为界面推断。

因此，从 SPSS 迁移到 PSPP 通常是低成本的，尤其当工作集中在描述统计、t 检验、相关、回归与常规方差分析时；而当流程依赖尚未实现的高级过程（如析因方差分析的 UNIANOVA、基于 GPL 的原始作图）时，则需要寻找替代路径或保留原有软件。认清这条边界，既能避免在不兼容命令上反复碰壁，也能在可行范围内充分享受开源方案带来的自由。

1.4 PSPP 的功能特点与适用场景

PSPP 的强项，在于把统计分析变得透明、可复现且零成本。它适合以下几类场景：

- **教学与入门**：命令与菜单——对应，便于讲解每一项统计量背后的计算逻辑，又不像商业软件那样带来授权负担。
- **中小规模数据分析**：问卷、实验记录、观测样本等常规体量下，PSPP 的描述统计、假设检验、方差分析与回归能力足以覆盖绝大多数课程与研究需求。
- **可复现的语法批处理**：把分析写成 .sps 语法文件，既能在 pspp 命令行批量重跑，也便于在服务器、容器等无图形界面的环境中复用，保证结果可审计、可追溯。
- **多格式输出**：分析产物可导出为 PDF、HTML、TeX 等，方便嵌入报告、网页与论文排版系统。

也必须正视它的局限。PSPP 当前不支持以下部分高级过程（手册第 21 章 Not Implemented 清单）：

- ANOVA 与 UNIANOVA（析因方差分析）：双因素及以上的方差分析在 PSPP 中须改用 GLM 命令，并在 / DESIGN 子命令中显式写出交互项（如 `age_group*sex`）。单因素方差分析仍可用 ONEWAY。
- GGRAPH、IGRAPH、XGRAPH（基于 GPL 的原始自定义作图）：PSPP 当前不支持，无法用 GPL 语言绘制任意图形；常规统计图应改用 GRAPH 或 FREQUENCIES/EXAMINE/CROSSTABS 内嵌的图形子命令。
- STEMLEAF（茎叶图）：PSPP 当前不支持；若需观察分布形态，可改用 FREQUENCIES /HISTOGRAM 或 EXAMINE /PLOT=HISTOGRAM 生成直方图替代。
- GET TRANSLATE：PSPP 当前不支持；导入 Excel 或 CSV 应改用 GET DATA /TYPE=ODS 或 GET DATA /TYPE=TXT。

- 另有 MANOVA、MULT RESPONSE、CURVEFIT、PLOT 等过程亦未实现。

这些缺口不影响 PSPP 在主流教学与中小规模分析中的可用性，但要求使用者清楚边界、及时转向可行方案，而非在缺失命令上反复碰壁。

1.5 本书约定与符号说明

为使后续各章口径一致，本书（技术侧）作如下约定：

命令、子命令、变量名、文件扩展名与英文菜单项一律保持英文原样，例如 COMPUTE、/VARIABLES、psppire、.sav，其后中文为说明。凡涉及图形界面的菜单路径，若属界面推断（即依据通用统计软件界面给出、手册未逐项文档化），均在附近标注“（界面推断，手册未逐项文档化）”，提示读者以实际软件为准。

代码示例使用围栏代码块呈现，保留英文原样。PSPP 命令以英文句点结尾；在交互提示符（如 PSPP>）下一行一条键入时，句点同样需要；而在某些特定提示符（如 data>）录入数据期间，则不要再重复输入句点。行内代码用反引号包裹。

统计符号采用通行约定：显著性水平记为 α ，概率值记为 p ，样本均值记为 $\bar{x}$ ，样本标准差记为 s 。其余统计量在正文首次出现时一并说明，避免读者来回翻查。

下面用一个轻量示例验证安装是否就绪：在终端运行 `pspp --version` 查看版本信息，或在图形界面中启动 `psppire`（界面推断，手册未逐项文档化）观察窗口是否正常弹出。两者任一成功，即表明 PSPP 已安装可用。

```
$ pspp --version
pspp (GNU PSPP) 2.0.1-gff8d3d
...
```

启动 PSPP 后，典型窗口由数据编辑器、语法编辑器（File → New → Syntax）与输出查看器组成；若窗口出现并能新建语法文件，便可进入后续章节的数据管理练习。本书随附示例所用的 `physiology.sav`、`personnel.sav`、`repairs.sav`、`horticulture.sav` 等数据均来自手册自带的示例集，纯属虚构，仅用于演示操作步骤，不得用于任何真实研究结论。# 第二章 安装与环境配置

PSPP 以两种面貌呈现在使用者面前：命令行程序 `pspp` 与图形界面 `psppire`。无论选择哪一种，安装本身都相当轻量，核心依赖与运行库随安装包一并到位，若干年前的老旧机器也足以胜任。本章先交代硬件与系统的底线要求，再分平台说明获取与安装途径，最后带你第一次启动程序、认识窗口布局，并讲清区域设置里最容易被忽视、却最容易引发数据错误的那个细节——小数点。

2.1 系统需求

PSPP 是跨平台软件，原生支持 Windows、macOS 与主流 Linux 发行版。它对运算资源并不挑剔，因为统计分析的瓶颈通常在数据规模与算法复杂度，而非界面渲染。一份常见的参考底线如下：处理器主频 1 GHz 以上即可；内存 512 MB 起步，处理数万行以上的数据集时建议 2 GB 或更多；硬盘预留约 200 MB 空间用于程序本体与文档。

上述数字属于通用建议，并非官方硬性门槛。实际的流畅程度取决于个案数、变量数以及所用命令的复杂度。命令行版 `pspp` 在内存受限的服务器甚至容器内也能运行，图形界面 `psppire` 由于需要 GTK 等图形库，对系统的依赖略多一点，但总体仍属轻量。值得提醒的是，PSPP 自身并不依赖数据库或后台服务，分析任务在本地独立完成，因而无需联网、也不涉及云端账号，这对涉及敏感数据的场景至关重要。当前发行以 64 位构建为主流，少数旧平台仍可找到 32 位版本；安装前确认系统架构与安装包匹配即可。

输出能力同样是考量因素之一。PSPP 当前的输出覆盖 ASCII、PostScript、PDF、HTML、DocBook、TeX 等格式，图形界面还能将结果导出为 SVG、PNG、OpenDocument 与 CSV，日常的查看、排版与分享需求基本都能就地满足，不必额外购置转换工具。

2.2 在 Windows 上安装 PSPP

Windows 用户最稳妥的获取渠道是 PSPP 官方网站提供的安装程序。该安装包为自包含格式，双击运行后按向导逐步确认即可完成部署；安装过程中通常会一并配置好运行 `psppire` 所需的图形库，无需使用者手动补齐依赖。若安装向导提供“添加到 PATH”之类的选项，建议勾选，这样在任意命令行窗口都能直接调用 `pspp`（界面推断，手册未逐项文档化）。

安装结束后，启动图形界面有几种常规途径：从开始菜单定位 PSPP 的快捷方式并点击，或在文件资源管理器中直接运行 `psppire` 可执行文件（界面推断，手册未逐项文档化）。若只需要命令行环境，可在开始菜单打开“命令提示符”或“PowerShell”，键入 `pspp` 后回车。官网偶尔也分发免安装的便携版本，解压即可运行，适合在受限制的公共电脑上临时使用（界面推断，手册未逐项文档化）。

下面这条命令用于确认安装是否成功、并查看当前版本号——它是手册真实支持的调用方式：

```
pspp --version
```

终端将回显版本信息（如 PSPP 2.0.1-gff8d3d）及许可证声明。看到类似输出，说明 pspp 已正确进入系统路径，后续章节的语法示例便可在此环境中验证。如果命令未被识别，多半是安装程序的路径未自动写入环境变量，重新检查安装选项或手动将程序目录加入 PATH 即可；想进一步了解可用命令，附加 --help 能列出全部支持的选项与子命令。

2.3 在 macOS 上安装 PSPP

macOS 平台上，除官网提供的安装包外，借助 Homebrew 等通用包管理器也能完成安装，例如在终端执行 `brew install pspp`（此为通用安装建议，请以官方安装说明为准）。通过包管理器安装的优点是易于后续升级与卸载，但首次拉取时可能连带下载若干依赖，需要保持网络畅通。较早期的 macOS 图形界面有时依赖 X11 类组件才能正常显示窗口，新版本多已内置所需库，具体以你所用构建的说明为准（界面推断，手册未逐项文档化）。

安装完成后，图形界面同样以 `psppire` 命名，可从启动台或应用程序目录中双击打开；命令行版本则继续通过终端调用 `pspp`。具体入口名称与图标样式随发行版本略有差异（界面推断，手册未逐项文档化），以你所用构建的实际表现为准。若从官网获取的是独立应用包，通常只需将其拖入“应用程序”文件夹便完成了全部安装动作；若系统提示来自未知开发者，需在安全性与隐私设置中手动允许，这属于 macOS 的常规 Gatekeeper 行为，并非安装包本身有误。

2.4 在 Linux 上安装 PSPP

绝大多数 Linux 发行版都可将 PSPP 纳入官方软件仓库或社区维护的源。基于 Debian 与 Ubuntu 的系统常通过 `apt` 获取，Fedora 与 RHEL 系则多用 `dnf`，Arch 用户可从 `pacman` 安装。这类方式属于通用建议，请参照你所处发行版的官方仓库说明操作——手册并未给出具体的逐条命令，各发行版的包名、版本与依赖解析方式也可能不同，照搬其它发行版的指令未必奏效。

仓库中的版本往往略滞后于上游最新发布，对绝大多数教学与常规分析而言并无差别；若确实需要某个新近修复的特性，可考虑从源码自行编译，但这条路径涉及构建工具链与依赖头文件，属于进阶操作，普通用户不必强求。安装后，`pspp` 与 `psppire` 一般已写入可执行路径，直接在终端输入对应名称即可启动。没有图形环境的服务器上，纯命令行的 `pspp` 足以驱动批处理式的统计分析任务，配合脚本还能实现无人值守的定时运算。

2.5 首次启动与界面初识

初次打开 `psppire`，映入眼帘的是数据编辑器（Data Editor）。它的顶部并排两个标签：**Data View** 与 **Variable View**。**Data View** 用于逐行查看与录入个案，每一行是一个个案，每一列是一个变量；**Variable View** 则负责定义变量的属性，诸如名称、类型、变量标签、值标签、缺失值规则等，都集中在这页设定。两页之间随时切换，变量结构的调整会立刻反映到数据视图的列定义上。

编写与运行语法，需要用到语法编辑器（Syntax Editor）。在菜单栏选择 `File → New → Syntax` 即可新建一个语法窗口（手册明示，此为手册明确记载的菜单路径）。将命令逐行写入后，借助 `Run` 菜单运行所选片段或整个文件（手册明示），结果会送往输出查看器。手册随附的示例数据集（如 `physiology.sav`、`personnel.sav`、`repairs.sav`、`horticulture.sav`）通常位于安装目录的 `examples` 子文件夹，初学时可拿来练手，但须记住它们纯属虚构，不可用于真实研究。

输出查看器（Output Viewer）是另一块固定区域，所有统计结果、表格与图形都在这里汇总呈现。它通常按“日志—结果”的结构组织：日志记录本次运行的命令与任何警告，结果部分才是真正的统计表与图形，便于回溯每一步操作是否如期执行。PSPP 支持将输出整体导出为多种格式，包括 PDF、PostScript、SVG、PNG、HTML、OpenDocument、CSV 与 TeX 等，足以覆盖从论文插图到网页发布的常见需要。

若想直接在终端唤起图形界面，可键入：

```
psppire
```

不附加参数时，程序会打开空白的数据编辑器等待进一步操作；偏好纯文本工作流的用户，也可仅启动 `pspp`，在 `data>` 提示符下一行行提交命令。需要留意，提示符状态下不要为命令末尾补上句点，句点仅用于正式的语法文件，即以英文句点 `.` 收尾命令；在交互提示符中输入命令本身即可，多余的句点反而会被当作内容的一部分。

2.6 语言与区域设置

区域设置 (locale) 决定了 PSPP 如何看待数字的书写。在英文 locale 下, 小数点用句点 . 表示, 例如 3.14; 而在部分欧洲语言的 locale 中, 小数点改用逗号 , , 千分位反而用句点。这一差异在数据录入阶段尤为危险: 当系统 locale 使用逗号作小数点时, 键入 12,5 很可能被程序当作“12 与 5”两段内容, 而不是“十二点五”, 由此引发的数值错乱极难事后察觉。区域设置对日期、列表分隔符的影响同样存在 (属通用配置知识), 但最常在统计场景里闯祸的, 仍是小数点这一个字符。

应对之策有两条。最彻底的是将工作环境切换为英文 locale, 让小数点回归句点; 若不便更改系统区域, 也可以在定义变量格式时显式锁定小数点字符。PSPP 允许在格式说明里加上 DOT 后缀来强制使用句点, 例如 DOT8.3 表示该数值字段总宽 8 位、含 3 位小数, 且小数点固定为 . , 不受 locale 影响。一个简短的声明如下:

```
NUMERIC income (DOT12.2).
```

意为变量 income 占用 12 个字符宽度、保留 2 位小数, 小数点始终以句点书写。教学与跨团队协作时, 显式指定 DOT 格式能有效规避逗号 locale 下的录入歧义, 比单纯依赖系统区域更可靠, 也避免了同一份语法在不同机器上得出不同结果。

至于界面语言本身, PSPP 借助 gettext 机制根据系统 locale 选择对应翻译, 因而菜单与提示语的语种通常跟随操作系统区域设置而定 (界面推断, 手册未逐项文档化)。若界面未呈现预期语言, 多半是 locale 或相应语言包尚未就位, 而非程序功能缺失; 确认系统区域与已安装的语言包后, 重启程序通常便能切换到位。# 第三章 数据管理

无论后续要做描述统计、假设检验还是回归建模, 所有分析都建立在同一块基石之上: 把原始信息整理成 PSPP 能够读懂的结构化数据。PSPP 处理的核心对象称为**数据集** (dataset), 它由一张二维表格承载——纵向的每一列是一个**变量** (variable), 横向的每一行是一个**个案** (case, 也称观测, observation)。数据分析本质上就是围绕这张表, 定义变量含义、录入或修改数值、筛选与变换个案, 最终产出可供统计过程读取的干净数据。本章把数据管理的全链路讲透: 从变量到底是什么、怎样新建并定义变量, 到怎样录入、从外部文件导入、怎样深入设置属性, 再到排序、拆分、筛选、计算新变量与重新编码, 最后落到数据清洗与缺失值处理的收尾环节。

为便于前后呼应, 本章贯穿一个小而完整的示例数据集: 一份班级学生调查与成绩记录。它包含学号 id、姓名 name、班级 class、性别 gender、语文 chinese、数学 math、英语 english、满意度 satisfaction (1~5 分) 与出勤率 attendance (0~100)。这份数据将反复出现在各节的示例中。

3.1 数据集与变量基础概念

理解 PSPP 的数据模型, 关键在于厘清三件事物及其关系。一张数据集像一本名册: 每一行记载一个具体对象 (这里就是一名学生) 的全部信息, 称为一个个案; 每一列描述所有对象共享的某一属性 (如语文成绩), 称为一个变量。同一个变量在不同个案上的取值各不相同, 这些取值的全体构成该变量的一列数据。个案与变量交叉处的单个数字或文字, 称作一个取值 (value)。

PSPP 中的变量只有**两种类型**, 这一点与许多现代表格软件不同, 却正是统计软件严格性的来源:

- **numeric (数值型)**: 存放可以参与四则运算的数字, 例如成绩、年龄、满意度评分。数值型变量支持计算、求均值、做方差分析等一切数学操作。
- **string (字符串型)**: 存放文本, 例如姓名、班级代号、开放性回答。字符串由字节序列构成, 不能直接参与算术运算。定义时需用 A 加宽度标明最大字节数, 例如 name (A12) 表示最多容纳 12 字节的字符串变量。

二者的区分看似简单, 却常常是初学者出错的根源: 把应当是数值的列误建成字符串, 后续 COMPUTE、MEANS 等过程便无法对该列求和; 反之把本该是文本的列建成数值, 中文姓名等非数字内容会被整列丢弃。因此, 在录入之前先想清楚“这一列将来要不要算数”, 远比事后补救来得经济。

在此还需铺垫一个与变量类型不同维度的概念——**测量尺度** (measurement level, PSPP 中称度量标准), 它描述变量取值背后的数学含义, 而非存储方式:

- **nominal (名义尺度)**: 取值仅代表类别, 彼此无大小顺序, 例如性别、班级、专业名称。
- **ordinal (有序尺度)**: 取值有先后次序, 但相邻间距未必相等, 例如满意度 1~5 分、成绩等级。
- **scale (标度尺度, 也称连续/定距尺度)**: 取值既有顺序又有可比较的等距, 通常可近似为连续量, 例如语文、数学、英语分数与出勤率。

测量尺度不影响数据存储, 却直接关系到哪些统计过程适用、结果应如何解读。例如对名义变量求“均值”通常没有意义, 而对标度变量做“中位数”虽可行却未必最优。PSPP 在过程层面会依据度量标准给出合适默认, 因此从一开始就把尺度设对, 能让后续分析少走弯路。下面的片段即用语法直观地展示了两类变量的声明方式:

```
DATA LIST LIST /id (F4) name (A12) gender (F1) chinese (F3).  
BEGIN DATA.
```

```
1001 张伟 1 88
1002 李娜 2 92
END DATA.
```

其中 id、gender、chinese 为数值型（F 起头指明数值格式），name 为字符串型（A12），二者混排于同一数据定义之中。运行后，数据集便拥有三列数值与一列文本，奠定了后续一切操作的结构基础。

3.2 新建数据文件与变量定义

在图形界面 psppire 中新建数据，核心是 **Variable View**（变量视图）这一标签页（界面推断，手册未逐项文档化）。它把每个变量的属性横向铺成一系列，逐列设定即可完成变量定义。PSPP 的 Variable View 通常包含以下十列，理解每一列的职责，是规范建表的第一步：

- **名称 (Name)**: 变量的唯一标识，须以字母开头、不含空格与中文，建议用英文或拼音缩写（如 chinese、attendance）。
- **类型 (Type)**: 在弹出的对话框中选择 numeric 或 string，并据此设定宽度与小数位；字符串类型在此指定最大字节数。
- **宽度 (Width)**: 变量显示与存储占用的字符总宽度，数值型与字符串型都适用。
- **小数 (Decimals)**: 数值型变量保留两位小数等显示位数。**务必注意**：这里只改变屏幕上显示的小数位，并不对原始数值做四舍五入——底层存储的是完整精度，显示成两位只是“看上去”被截断。
- **标签 (Label)**: 变量的中文或长说明，例如把 chinese 标为“语文成绩”。标签不参与运算，仅用于输出中替代生硬的代码名，提升可读性。
- **值标签 (Values)**: 为离散取值附加文字说明，例如给 gender 的 1 配“男”、2 配“女”。面向类别变量时，值标签让输出表格从一堆数字变为可读文字。
- **缺失 (Missing)**: 声明哪些取值代表缺失（详见 3.5 与 3.8 节）。
- **列宽 (Columns)**: 该列在 Data View 中显示的宽度，纯界面偏好，不影响数据。
- **对齐 (Align)**: 单元格内文字的左/中/右对齐方式，同样只关乎显示。
- **度量标准 (Measure)**: 即 3.1 节所述的 nominal / ordinal / scale，在此下拉选择。

完成十列定义后，切到 Data View 即可录入数据。然而，纯图形点的方式难以复现、不易批量修改。更受教材与科研推崇的做法是用 DATA LIST LIST 语法一次性声明变量结构——它等价于在 Variable View 中把所有列填好，且可被保存为 .sps 文件反复运行。语法形式如下：

```
DATA LIST LIST
  /id (F4) name (A12) class (A1) gender (F1)
    chinese (F3) math (F3) english (F3)
    satisfaction (F1) attendance (F3).
VARIABLE LABELS
  id '学号' name '姓名' class '班级' gender '性别'
  chinese '语文成绩' math '数学成绩' english '英语成绩'
  satisfaction '满意度(1-5)' attendance '出勤率'.
```

DATA LIST LIST 后逐列写明变量名与格式。这里的 F 与 A 是**格式类型字母**（format type letter），并不是子命令——数值格式以 F 开头（如 F4、F3），字符串格式以 A 开头（如 name (A12)、class (A1)）；PSPP 的变量只有 numeric 与 string 两种类型，二者混排于同一数据定义之中即可声明整张表。紧接着的 VARIABLE LABELS 为各变量补上中文标签，相当于填好了 Variable View 的“标签”列。这套语法一旦写好，无论谁在何种机器上运行，得到的变量结构都分毫不差——这正是语法驱动 workflow 相对手工点选的最大优势。

3.3 数据录入与编辑

变量结构定义好之后，下一步是把具体数值填进表格。最直观的方式是在 Data View 中点击单元格直接键入（界面推断，手册未逐项文档化）：每一行对应一个学生，依次填入学号、姓名、各班成绩等。单元格录入胜在所见即所得，适合少量、零散的数据补录与修正。

但当数据量较大、或希望录入过程可复现时，应当回到语法：把 DATA LIST 与 BEGIN DATA / END DATA 配对使用，把全部数据作为语法的一部分一次性灌入。沿用 3.2 节的变量定义，完整的录入示例如下：

```
DATA LIST LIST
  /id (F4) name (A12) class (A1) gender (F1)
    chinese (F3) math (F3) english (F3)
    satisfaction (F1) attendance (F3).
BEGIN DATA.
1001 张伟 A 1 88 95 90 5 96
```



```

1002 李娜 B 2 92 88 85 4 91
1003 王芳 A 2 79 82 88 3 88
1004 刘洋 C 1 65 70 72 2 75
1005 陈静 B 2 95 91 93 5 98
1006 赵磊 C 1 58 63 60 1 70
END DATA.

```

录入要点有三。其一，DATA LIST 与 BEGIN DATA/END DATA 必须三件套齐备、——配对，缺一不可。其二，数据行须严格按变量定义的次序与宽度排列：字符串如 name (A12) 宽度足够，class (A1) 只占 1 字节故只写一个字母；数值按 F 格式对齐，字段间以空白分隔即可。其三也是最易踩的坑——END DATA. **必须独占一行**，且以英文句点收尾。若把 END DATA. 与某行数据写在同一行，或漏掉句点，PSPP 会继续把后续内容当作数据读取，导致结构错乱甚至语法报错。

运行上述代码片段后，六个学生的全部信息便落入活动数据集。此时在 Data View 中可见六行九列的完整表格；若此前已用 VARIABLE LABELS 加过标签，输出与浏览时列头将显示中文而非代码。需要指出的是，录入进内存的数据尚未存盘，关闭前务必用 SAVE (见 3.8 节) 写出为 .sav 系统文件，否则改动会在退出时丢失。

3.4 从外部文件导入数据

现实中大量数据已经存在于 Excel、OpenDocument 表格或 CSV/文本文件中，逐行手工键入既低效又易错。PSPP 提供了 GET DATA 命令专门读取这些外部格式，但有一个极易混淆的边界必须首先厘清。

IMPORT 与 GET DATA 是两回事。IMPORT 命令 (详见 IMPORT 节点) 只能读取 PSPP 自身的系统文件 (.sav) 与便携文件 (.por)，它无法直接打开 Excel 工作簿或 CSV 文本。凡遇到 Excel/ODS/CSV/纯文本，正确的入口永远是 GET DATA，而非 IMPORT。初学者常误以为“导入”都走 IMPORT，结果面对 .xlsx 无所适从——记住：外部表格用 GET DATA，PSPP 自家文件才用 IMPORT。

GET DATA 通过 /TYPE 子命令区分来源，而 /TYPE 又是**必须且必须作为第一个**出现的子命令，取值包括 GNM (Gnumeric)、ODS (OpenDocument，兼容多数 .ods 及现代 Excel 导出的开放格式)、PSQL (PostgreSQL) 与 TXT (文本/CSV)。下面分别给出两类最常见场景的完整语法。

场景一：导入 Excel/ODS 电子表格

```

GET DATA /TYPE=ODS /FILE='students.ods'
        /SHEET=NAME 'Sheet1'
        /CELLRANGE=FULL
        /READNAMES=ON
        /ASSUMEDSTRWIDTH=32.

```

关键子命令说明：/SHEET=NAME 'Sheet1' 指定工作表，也可用 /SHEET=INDEX n 按序号选定；/CELLRANGE=FULL 读取整张表，亦可用 /CELLRANGE=RANGE 'C3:P19' 仅取某个矩形区域；/READNAMES=ON (默认值即开启) 把首行当作变量名读入，而非当作数据；/ASSUMEDSTRWIDTH=32 给未被显式指定宽度的字符串变量预设 32 字节——**这一点尤其要留心**，PSPP 对字符串宽度的默认假设偏窄，长文本列若不加此声明容易被截断，故建议显式给定足够宽度。

场景二：导入 CSV/分隔文本

```

GET DATA /TYPE=TEXT /FILE='students.csv'
        /ARRANGEMENT=DELIMITED
        /DELIMITERS=', '
        /FIRSTCASE=2
        /VARIABLES=id F4 name A12 class A1 gender F1
                    chinese F3 math F3 english F3
                    satisfaction F1 attendance F3.

```

此处 /ARRANGEMENT=DELIMITED 表明文件以分隔符划分字段；/DELIMITERS=', ' 指明逗号分隔，制表符需用 \t 表示；/FIRSTCASE=2 告知程序跳过第 1 行表头、从第 2 行起读数据——**忘记这一行，表头文字会被当成第一条个案，字符串列尚能容错、数值列则会引入脏数据。**最后的 /VARIABLES= 逐个列出变量名与格式，它**必须放在所有子命令的最后**，且是必填项：PSPP 不会像电子表格那样自动推断类型，而要靠你在这里明确每份字段是 F (数值) 还是 A (字符串) 及其宽度。

无论哪种导入，结果都进入内存中的活动数据集，原文件不被改动。读完建议立即用 SAVE 落盘为 .sav，以免重复导入。若导入后字符串出现莫名截断或首行混入了表头，回头检查 /ASSUMEDSTRWIDTH 与 /FIRSTCASE 这两项即可定位。

3.5 变量属性的深入设置

建好变量、录入数据之后，真正的“数据管理工作”才刚开始。一份能被统计过程正确理解的数据，离不开对标签、值标签、缺失值与度量标准的精细设定。这些属性在 Variable View 中可点选设置，也可用对应命令一次性批量声明——后者显然更利于复现。

变量标签 VARIABLE LABELS 为变量附加说明文字，输出表格的列头将显示标签而非代码：

```
VARIABLE LABELS gender '性别' satisfaction '课程满意度(1-5)' attendance '出勤率(%)'.
```

值标签 VALUE LABELS 为离散取值对应文字，是类别变量可读化的关键。需要特别记住：VALUE LABELS 会清空该变量已有的全部值标签后再写入，因此它适合首次定义；若要在此基础上追加而不破坏既有标签，须改用 ADD VALUE LABELS。

```
VALUE LABELS gender 1 '男' 2 '女'.
```

```
ADD VALUE LABELS satisfaction 1 '非常不满意' 2 '不满意' 3 '一般' 4 '满意' 5 '非常满意'.
```

上面先为 gender 定义男女，再用 ADD VALUE LABELS 把满意度的五级文字补上，二者互不干扰。若误用 VALUE LABELS 去加第五级，前面四级的标签将被一扫而空。

缺失值 MISSING VALUES 声明哪些取值代表“缺失”，是数据清洗的基石（详见 3.8 节）。数值型变量最多可声明 3 个离散缺失值，或一个连续范围；字符串变量规则相同。范围用 THRU 衔接，端点可用 LO/LOWEST 与 HI/HIGHEST 指代最小、最大边界：

```
MISSING VALUES attendance (999) satisfaction (LO THRU 0).
```

本例把出勤率的 999（明显不可能的值）与满意度中“0 及更小”的区间一并标为缺失。此后多数统计过程默认将这些取值排除在计算之外，从而免于污染均值与标准差。

度量标准 VARIABLE LEVEL 显式指定变量的测量尺度，呼应 3.1 节的铺垫：

```
VARIABLE LEVEL gender class (NOMINAL) satisfaction (ORDINAL)  
chinese math english attendance (SCALE).
```

这样，gender 与 class 被标为名义、satisfaction 为有序、各成绩与出勤率为标度。过程在默认行为上会参考这一设定，例如对名义变量避免给出无意义的均值。把 3.5 节的四条命令与 3.2、3.3 节的建表录入串成一段语法，便构成了这份学生数据集“从结构到语义”的完整定义，后续所有分析都建立在它之上。

3.6 数据整理：排序、拆分文件、选择个案

数据落盘之后，往往要先按分析意图重新排列或切分，再交给统计过程。这一节的三组命令分别解决“排顺序”“分组算”“取子集”三类需求。

SORT CASES 按指定变量对个案重新排序，菜单路径为 Data → Sort Cases【手册明示】。语法中可用 (D) 或 (DOWN) 表示降序，(A) 或 (UP) 表示升序，省略则默认升序：

```
SORT CASES BY class (A) chinese (D).
```

上述命令先按班级升序、班级内再按语文成绩降序排列六个学生。需要强调：SORT CASES 只改变内存中活动数据集的序，**不会改动原 .sav 文件**，要保留排序结果仍需 SAVE。

SPLIT FILE 让后续统计过程按某个（或几个）分组变量分别出具结果，而不必手动拆表。它有两种模式：LAYERED（默认，各组的表合并在同一输出中便于对照）与 SEPARATE（每组独立成表）。关闭拆分用 SPLIT FILE OFF.：

```
SORT CASES BY class (A).  
SPLIT FILE LAYERED BY class.
```

这里先按 class 排序再拆分，次序并非偶然——SPLIT FILE 在分组时只识别**相邻的同类个案**，若事先未排序，同一班级的学生可能分散在多处，拆分出的结果就会支离破碎。拆分效果会一直持续，直到显式 SPLIT FILE OFF. 才解除，因此分析完一组后别忘了关掉，否则后续无关过程也会被无谓分组。

SELECT IF 与 FILTER 都用于“只保留部分个案”，但性质截然相反，这是本节最需警觉的分水岭。SELECT IF 会**永久删除**不满足条件的个案——除非用 TEMPORARY 包裹，否则被剔除的数据无从恢复：

```
SELECT IF attendance >= 75.
```

执行后，出勤率低于 75 的学生（如示例中 attendance 为 70 的赵磊）将从数据集中彻底消失。相比之下，FILTER 只是“过滤”而非“删除”：被过滤变量取值为 0 或缺失的个案在分析中暂时隐藏，却仍留在数据集里，用 FILTER OFF. 即可原样恢复：

```
COMPUTE flag = (attendance >= 75).
FILTER BY flag.
* 此时低于75的个案被暂时排除，但数据仍在
FILTER OFF.
```

一个来自手册的 SELECT IF 实例是 SELECT IF dob > date.dmy(31,12,1999).，即仅保留 1999 年底之后出生者。请务必牢记：删除不可逆，过滤可恢复。在拿不准该不该丢掉数据时，优先用 FILTER 试探，确认无误后再考虑 SELECT IF。

3.7 变量计算与重新编码

原始数据 seldom 直接满足分析需要：常常要由既有变量算出新指标，或把连续分数归并成等级。PSPP 提供 COMPUTE 与 RECODE 两件利器应对这两种场景。

COMPUTE 按表达式生成（或覆盖）一个变量，语法为 COMPUTE variable = expression.。若目标变量是数值型且尚不存在，PSPP 会自动新建它，默认格式 F8.2：

```
COMPUTE total = chinese + math + english.
COMPUTE average = total / 3.
```

这两行算出了每个学生的总分与三科平均。然而，当目标变量是**字符串**时，绝不可依赖自动新建——必须先以 STRING 命令显式声明其宽度，否则 COMPUTE 会因目标类型不明而报错或产生不可预期结果：

```
STRING remark (A6).
COMPUTE remark = '已录入'.
```

这里先用 STRING remark (A6). 把目标建成 6 字节字符串，再将 COMPUTE 的结果写入，次序不可颠倒。菜单上对应操作位于 Transform → Compute Variable（界面推断，手册未逐项文档化）。

RECODE 把变量的取值按规则映射为新值，常用于分数分级、异常值归并。语法为 RECODE src_vars（源值 = 目标值）... [INTO dest_vars].，省略 INTO 则就地改写源变量，写上 INTO 则把结果存入新变量、保留原值。它支持丰富的特殊记号：THRU 表示含端点的区间；LO/LOWEST 与 HI/HIGHEST 指代最小、最大边界；MISSING、SYSMIS 匹配缺失；ELSE 兜住前面未覆盖的一切（**必须放在最后一组**）；COPY 表示原样保留；（CONVERT）可把数值型字符串先转为数值再判断。多组规则之间用 / 分隔。

```
RECODE total
  (LOWEST THRU 179 = 1)
  (180 THRU 209 = 2)
  (210 THRU 239 = 3)
  (240 THRU HIGHEST = 4)
  INTO level_num.
ADD VALUE LABELS level_num 1 '不及格' 2 '及格' 3 '良好' 4 '优秀'.
```

上面把总分分为四级并写入新变量 level_num，再用 ADD VALUE LABELS 配文字。若想把等级直接存成字符串字母，则目标须先 STRING：

```
STRING grade (A6).
RECODE total
  (LOWEST THRU 179 = '不及格')
  (180 THRU 209 = '及格')
  (210 THRU 239 = '良好')
  (240 THRU HIGHEST = '优秀')
  INTO grade.
```

另一个展示 SYSMIS 与 COPY 的手册式示例是 RECODE x y (0 = 99) (1 THRU 10 = COPY) (1000 THRU HIGHEST = SYSMIS) (ELSE = 999).：它把 0 改写为 99、1~10 原样保留、1000 及以上标为系统缺失、其余一律填 999。善用这些记号，重新编码既能清理异常，又能无损地衍生出可供分组分析的新类别变量。

3.8 数据清洗与缺失值处理

把前面各节串起来，数据管理的最终落点便是清洗：识别并妥善处理脏数据与缺失值，再把整理好的数据集稳妥保存。MISSING VALUES（3.5 节）所定义的那些取值，在 PSPP 中称为**用户缺失值**（user-missing）。它们的关键作用在于：多数统计过程默认会将用户缺失值在分析中排除，例如 DESCRIPTIVES 默认 NOINCLUDE，意味着被标为缺失的出勤率 999 不会进入均值与标准差的计算，从而避免一个荒谬的取值拉偏整列统计量。若确有

需要把缺失值也纳入，才须显式附加 INCLUDE 子命令——这一默认排除机制，正是 3.5 节强调“先标缺失、再算统计”的原因。

一套完整的清洗流程通常如下：先以 MISSING VALUES 锁定异常码（如 attendance（999）），必要时用 RECODE 把这些异常归并或标为缺失；再以 SELECT IF 或 FILTER 剔除无效个案（注意前者的不可逆性）；随后用 COMPUTE 与 RECODE 衍生分析所需的总分、等级等变量；最后把内存中这版干净数据写出为系统文件，供后续章节的统计分析直接读取：

* 数据清洗与保存示例

```
MISSING VALUES attendance (999).  
COMPUTE total = chinese + math + english.  
RECODE total (LOWEST THRU 179 = 1)(180 THRU 209 = 2)  
          (210 THRU 239 = 3)(240 THRU HIGHEST = 4) INTO level_num.  
ADD VALUE LABELS level_num 1 '不及格' 2 '及格' 3 '良好' 4 '优秀'.  
SAVE OUTFILE='students_clean.sav'.
```

收尾的 SAVE OUTFILE='students_clean.sav'。把清洗后的活动数据集持久化为 PSPP 系统文件。需要认清：SAVE 写出的是当前内存中的全部内容——包括排序结果、拆分状态解除后的数据、以及所有新建与重编码的变量；而像 SPLIT FILE 这类“过程状态”本身不会被存进文件。此后在第四章及以后的描述统计中，只需 IMPORT 读回这份 .sav，便能以一份语义清晰、缺失妥善处理的数据，直接进入均值、频率与图表的分析，不必再重复本章的整理劳动。

至此，从理解变量类型、建表定义、录入与导入，到属性设定、排序拆分筛选、计算重编码，直至清洗保存，数据管理的完整链路已经闭合。它所产出的那份干净数据集，正是全书中所有统计操作的共同起点。# 第四章 描述性统计分析

描述性统计是任何量化分析的第一站。拿到一份数据集，最忌讳的是跳过观察直奔假设检验。推断统计（t 检验、方差分析、回归）的结论往往建立在“数据大致长成某种形状”的前提之上——正态、方差齐、无极端个案。若连集中位置与离散程度都不清楚，后续的显著性结论很可能建立在流沙之上。先描述、后推断，不是仪式感，而是让每一步结论都有据可依；它还能在最早阶段揪出录错的数据、异常的缺失值，省去后面反复返工。

4.1 描述性统计的意义

描述一个变量，通常从两个维度入手。其一是**集中趋势**（central tendency），回答“典型值在哪”：最常用的指标是均值（所有取值的算术平均）、中位数（排序后居中的那个值，对极端值不敏感）、众数（出现最频繁的值，对分类变量尤其有用）。其二是**离散趋势**（dispersion），回答“数据散得有多开”：标准差与方差量化了每个取值偏离均值的平均距离；极差（最大值减最小值）最直观却最易受极端值摆布；四分位距（上四分位数减下四分位数）则刻画了中间一半数据的跨度，稳健性更好。

对初学者而言，一个朴素的判断法则则是：先看变量是**分类变量**还是**连续变量**。性别、专业这类分类变量，适合数一数每一类有多少人（频率分析）；成绩、时长这类连续变量，则适合报出均值、标准差并观察分布形态。把工具选错比算错更常见——对性别去求“均值”并无意义，对成绩去数“众数”也丢了大部分信息。

描述统计不只是推断的前奏，它本身常常就是答案。一份调查报告、一张成绩册，读者最想看的往往就是“平均分多少、分布是否均衡”，而非某个检验的 p 值；把描述结果讲清楚，报告就立得住。此外，分布形态直接决定后续该走哪条路：连续且近似正态，均值与 t 检验顺理成章；严重偏态或有极端值，就该考虑中位数、对数变换或非参数方法。先描述，等于先为整份分析定调。

PSPP 把这套工具拆成了五条命令，各司其职：

- FREQUENCIES：面向分类变量，给出频次、百分比并可可视化条形图或直方图；
- DESCRIPTIVES：面向连续变量，报告均值、标准差等核心统计量，还能顺手算 Z 分数；
- EXAMINE：探索性分析，分组给出详细统计量并绘制箱线图、直方图，附正态性检验；
- CROSSTABS：两个分类变量交叉，看是否有关联，并做卡方检验；
- MEANS：按一个或多个分组变量求连续变量的分组均值。

本章后续四节逐一展开前四条命令；MEANS 用法与 EXAMINE 的分组思路相近，在菜单 Analyze → Compare Means → Means 中（界面推断，手册未逐项文档化）。

下面给出一个最小可运行示例，体会 MEANS 的输出：

```
MEANS score BY gender.
```

该命令会按 gender 的每一个取值（男、女）分别输出 score 的**均值**（Mean）、**标准差**（Std. Deviation）与**个案数**（N）等分组统计量；若想知道组间差异是否显著，可在 /STATISTICS 中追加均值标准误等，配合后续的 t 检验或单因素方差分析判断。与 EXAMINE 相比，MEANS 输出更紧凑，专注于“分组均值”这一件事。

4.2 频率分析

FREQUENCIES 是认识分类变量的起点。它会为每个变量输出一张频率表，含四栏：频次（Frequency，即该取值出现的次数）、百分比（Percent，频次除以总个案数）、有效百分比（Valid Percent，频次除以“有效个案数”，即剔除缺失值之后）、累积百分比（Cumulative Percent，自上而下累加，对有序变量才有意义）。

语法层面，/VARIABLES 列出要分析的变量，/STATISTICS 可附加中位数、众数、偏度、峰度等（偏度、峰度仅对连续数值变量有意义，对性别、专业这类分类变量不应请求）。此外 /STATISTICS 还支持 PERCENTILES（指定分位数）与 NTILES=4（四等分位数，即四分位数），便于报告 P25、P50、P75 这类分位指标。

```
FREQUENCIES /VARIABLES=gender major
              /STATISTICS=MEDIAN MODE
              /BARCHART.
```

这里 gender 是数值变量、带值标签（1=男，2=女），major 是字符串变量（物理、化学、生物、数学）。需要留意的细节是：FREQUENCIES **对字符串变量不画直方图**——直方图依赖连续取值的等距分箱，字符串无此性质，因此 /HISTOGRAM 子命令遇到字符串变量会被静默忽略，改用 /BARCHART 才是正确做法。直方图只对数值变量生效；若想叠加正态曲线，可写 /HISTOGRAM=NORMAL。

下面沿用第三章的学生调查数据集（虚构示例数据，仅作教学），先看性别分布：

```
DATA LIST LIST /id (F4) gender (F1) major (A8) score (F5.1) study_hours (F4.1).
BEGIN DATA.
```

```
1001 1 物理 85.5 20.0
1002 2 化学 78.0 15.5
1003 1 生物 92.0 25.0
1004 2 物理 68.5 12.0
1005 1 数学 88.0 22.0
1006 2 生物 74.0 16.0
1007 1 化学 81.0 18.0
1008 2 数学 90.5 24.0
1009 1 物理 76.0 14.0
1010 2 化学 83.5 19.0
1011 1 生物 95.0 28.0
1012 2 数学 70.5 13.0
1013 1 数学 87.0 21.0
1014 2 物理 79.0 17.0
1015 1 化学 84.0 20.0
1016 2 生物 72.0 14.5
1017 1 物理 90.0 26.0
1018 2 数学 85.0 23.0
1019 1 化学 77.5 15.0
1020 2 生物 80.0 18.5
END DATA.
```

```
VARIABLE LABELS gender '性别' major '专业' score '期末成绩' study_hours '每周学习时间(小时)'.
VALUE LABELS gender 1 '男' 2 '女'.
```

```
FREQUENCIES /VARIABLES=gender /STATISTICS=MEDIAN MODE.
```

输出要点：20 名受试者中男、女各 10 人，频次均为 10，百分比与有效百分比均为 50.0%，因无缺失值二者相等；累积百分比在“女”一行达到 100.0%。理解“百分比”与“有效百分比”的差别很关键：当数据里存在缺失值（例如某位受试者未填性别），“百分比”仍按全部 20 个个案为分母，而“有效百分比”只按填了的 19 个有效个案计算，二者会拉开差距——报告时通常报有效百分比更诚实。“累积百分比”沿取值顺序累加，对性别这类名义变量只是凑数，对“学历”“满意度等级”等有序变量才有意义，能读出“多少比例落在某等级及以下”。/STATISTICS=MEDIAN MODE 额外报告中位数与众数——性别这类二分类变量的众数就是出现更频繁的那一类别（本例并列）。若对成绩 score 这类连续变量运行 FREQUENCIES /HISTOGRAM=NORMAL，还能从直方图形状和偏度（Skewness）、峰度（Kurtosis）数值判断分布是否左偏、右偏或尖峭。菜单路径为 Analyze → Descriptive Statistics → Frequencies（界面推断，手册未逐项文档化）。

4.3 描述统计

当变量是连续型，DESCRIPTIVES 比 FREQUENCIES 更对口。它默认报告五个数：个案数 N、最小值、最大值、均值、标准差，以及**均值标准误**（S.E. Mean，等于标准差除以样本量的平方根）。均值标准误在构造置信区间、

与理论值比较时都要用到，标准误越小，样本均值对总体均值的估计越精确。

DESCRIPTIVES /VARIABLES=score study_hours /SAVE.

/SAVE 是本命令的特色：它把每个变量的 Z 分数另存为新变量。Z 分数表示某个取值距离均值有多少个标准差，公式为 $Z = (x - \text{均值}) / \text{标准差}$ 。上方命令执行后，数据集里会新增 Zscore 与 Zstudy_hours 两个变量，便于后续做标准化比较或筛选异常个案（例如挑出 $|Z| > 3$ 的极端记录）。注意默认情况下 DESCRIPTIVES 排除用户定义的缺失值（即 NOINCLUDE），若要把缺失值编码也纳入计算，需显式加 INCLUDE。

沿用同一数据集，运行上面语法后，典型输出大致如下（数值为示意）：成绩均值约 82.5、标准差约 7.3、均值标准误约 1.63，最小值 68.5、最大值 95.0；每周学习时间均值约 19.2 小时、标准差约 4.4。解读时，若两份调查的均值标准误相差明显，标准误小者给出的均值更可信。标准差衡量组内差异：两组均值相同，标准差小的一组成绩更整齐。均值标准误则反映抽样的稳定性，乘以 1.96 大约得到 95% 置信半宽——这是把“样本均值”推广到“总体均值”的桥梁。Z 分数除了定位极端个案，还用于把不同量纲的变量拉到同一尺度（均值为 0、标准差为 1），在后续做综合评分或距离计算时尤为方便。菜单路径为 Analyze → Descriptive Statistics → Descriptives（界面推断，手册未逐项文档化）。

4.4 交叉表分析

许多研究问题关注的是“两个分类变量是否相关”。CROSSTABS 把两个分类变量做成列联表，并给出卡方检验。基本语法为：

```
CROSSTABS /TABLES=major BY gender
          /CELLS=COUNT ROW COLUMN TOTAL EXPECTED
          /STATISTICS=CHISQ.
```

/TABLES=major BY gender 表示行变量为 major、列变量为 gender。/CELLS 决定格子里显示什么：COUNT（频数，默认）、ROW（行百分比）、COLUMN（列百分比）、TOTAL（合计百分比）、EXPECTED（期望频数）。PSPP 默认已含 COUNT、ROW、COLUMN、TOTAL，上面又补了 EXPECTED，便于核对“实际频数与期望频数差多少”；若再加 RESIDUAL，格子还会显示残差（观察减期望），残差大的格子暗示该组合的关联贡献最多。/STATISTICS=CHISQ 触发卡方族检验。

以专业 × 性别为例，下方列联表给出各组合的观测计数与期望计数（数据虚构，仅示意）：

专业	男（计数 / 期望）	女（计数 / 期望）	合计
物理	3 / 2.5	2 / 2.5	5
化学	3 / 2.5	2 / 2.5	5
生物	2 / 2.5	3 / 2.5	5
数学	2 / 2.5	3 / 2.5	5
合计	10	10	20

从上表已能直观看出：物理、化学呈“男多女少”，生物、数学则“女多男少”，这种交错格局正是卡方检验要量化为显著与否的关联。卡方检验表则告诉我们，这种差异是否大到不能简单归因于随机抽样波动。

下方“卡方检验”表同时列出四项关键结果：

- **Pearson χ^2** ：最常用，比较观察频数与期望频数；
- **似然比 (Likelihood Ratio)**：大样本下与 Pearson 结论一致，对小样本更稳；
- **Fisher 精确检验 (Fisher's Exact Test)**：当期望频数过小（尤其有格小于 5）时，Pearson 不再可靠，此时应读 Fisher 的显著性；
- **连续性校正 (Continuity Correction)**：仅对 2×2 表提供，Yates 校正缓和了离散数据对连续 χ^2 分布的近似偏差。

卡方的直觉是“观察频数与期望频数的差距平方，再按期望频数缩放后求和”：差距越大、期望越小，卡方值越高，越倾向于认为两变量不独立。期望频数由“行合计 × 列合计 ÷ 总合计”得到，因此样本量太小或某类组合本就稀少时，期望频数会被压低，Pearson 近似失效——这正是 Fisher 精确检验与连续性校正存在的理由。

解读原则：先看期望频数——上表每个期望频数都约为 2.5（远低于 5），Pearson χ^2 在此已不可靠，应优先参考 Fisher 精确检验；否则看 Pearson χ^2 的显著性（Asymptotic Significance）。若 $p < 0.05$ ，认为两变量存在显著关联； $p \geq 0.05$ 则无充分证据认为相关。对于 2×2 表，连续性校正的值往往比未校正更保守，报告时应注明用的是哪一种。菜单路径为 Analyze → Descriptive Statistics → Crosstabs（界面推断，手册未逐项文档化）。

4.5 探索性数据分析

EXAMINE 是为“把数据看透”而生的命令：它既能按分组输出详尽统计量，又能画箱线图、直方图，并在请求图形时自动附带 Shapiro-Wilk 正态性检验。语法骨架是：

```
EXAMINE score BY gender
        /STATISTICS=DESCRIPTIVES
        /PLOT=BOXPLOT HISTOGRAM
        /ID=id
        /NOTOTAL.
```

VARIABLES=score BY gender 指定因变量 score 与分组因子 gender；省略 BY 则做整体分析。/STATISTICS=DESCRIPTIVES 给出均值、中位数、标准差、四分位数、极值等；/PLOT=BOXPLOT 画箱线图、HISTOGRAM 画直方图，亦可写 ALL 一次性要全，或加 NPLOT 要正态概率图。一个关键约束：**只要请求了图形 (BOXPLOT/NPLOT/HISTOGRAM)，PSPP 就会自动执行 Shapiro-Wilk 正态性检验**；该检验对加权数据要求权重为整数、累计个案数落在 3 到 5000 之间，否则检验无法给出。

/ID=id 让极端值在输出中标注具体个案编号，而非只报“第几个”；/NOTOTAL 取消汇总那一栏（默认会多出一个 Total 组，把全体个案合在一起再算一遍）。

沿用数据集，运行上方语法后可得两套输出（男、女各一）。箱线图的解读：箱子覆盖中间 50% 数据（下四分位到上四分位），箱内横线是中位数，须线延伸至 1.5 倍四分位距内的最远点，超出者以独立点标出，即为可疑极端值——结合 /ID=id 我们能立刻定位到是哪位学生。箱线图的须线规则值得记牢：上须取到“不超过 1.5 倍四分位距的最大值”，下须取到“不低于 1.5 倍四分位距的最小值”，落在 1.5~3 倍四分位距外的点标为圆点（可疑异常值），超过 3 倍者标为星号（极极端值）。这套规则让箱线图一眼区分“正常波动”与“真正反常”。/STATISTICS=DESCRIPTIVES 同页还会列出上下若干个极端个案的取值，配合 /ID 即可追到原始记录。/STATISTICS=DESCRIPTIVES 同页还会报告偏度与峰度。正态性方面，Shapiro-Wilk 表给出统计量 W 与显著性：当显著性大于 0.05，数据与该组正态假设不矛盾；小于 0.05 则提示可能偏离正态，后续若做 t 检验之类依赖正态的推断，就得谨慎或改用非参数方法。需要补充一点：Shapiro-Wilk 对大样本过于敏感——样本量很大时，即便偏离很小也会判为“不正态”；样本量很小时又容易漏判。因此正态性不能只看 p 值，要连同直方图、箱线图与偏度共同判断，这也正是 EXAMINE 把图形与检验打包给出的用心所在。

需要提醒：PSPP 当前未实现茎叶图 (STEMLEAF) 与原始 GPL 作图 (GGRAPH/IGRAPH/XGRAPH)，探索分布形态须借助 EXAMINE 的直方图、箱线图或 GRAPH 命令。菜单路径为 Analyze → Descriptive Statistics → Explore（界面推断，手册未逐项文档化）。# 第五章 假设检验基础

5.1 统计推断与假设检验的基本思想

手里攥着一份样本，心里却惦记着总体——这是数据分析里最寻常的张力。我们不可能、也不必要把每一个个体都测量一遍，于是只能从样本出发，去推断总体的模样。假设检验，就是这套“由局部看全局”的推理工具中最核心的一件。

它始终在比较两种说法。一种是保守的、现状式的断言，称为**零假设**（null hypothesis，记作 H_0 ）；另一种是研究者真正想支持的、带有变化意味的断言，称为**备择假设**（alternative hypothesis，记作 H_1 ）。举个例子：药厂声称某种胶囊的平均装量为 500 毫克，质检员怀疑实际偏少。这时 H_0 就是“平均装量等于 500 毫克”， H_1 则是“平均装量不等于（或小于）500 毫克”。检验不预先相信哪一边，它只是问：如果 H_0 真的成立，我们眼前这份样本出现的概率，大到让人安心，还是小到令人起疑？

背后的逻辑叫**小概率原理**：一件概率极小的事件，在一次试验中几乎不该发生。倘若在“ H_0 成立”的前提下，当前样本的出现概率小到了预先划定的门槛以下，我们就有理由怀疑 H_0 本身站不住脚，从而转而支持 H_1 。注意，这不是“证明了” H_1 ，而是“ H_0 难以解释眼前的数据，所以暂且放下它”。

被反复提及的 **p 值**，就是上面的“概率”本身。更准确地说，p 值是在 H_0 成立的前提下，观察到当前样本、或更极端样本的概率。把它想成一份“意外程度报告”最贴切：p 值很小，意味着“若 H_0 为真，眼前这般甚至更离谱的结果本不该轻易撞见”；p 值很大，则意味着“这个结果在 H_0 的世界里稀松平常，没什么好大惊小怪”。p 值小到什么程度才算“离谱”？这个门槛由研究者事先定下，正是下一节要谈的显著性水平。

检验本身还分“双侧”与“单侧”两种姿态。若 H_1 只笼统地说“两者不相等”，我们得两侧都提防，这叫**双侧检验**；若 H_1 带着明确方向，例如“装量低于标准”或“新法得分更高”，只需盯着那一侧，这叫**单侧检验**。单侧把全部 α 押在一边，自然更容易在那一端达到显著，但方向必须在事前就有充分依据，不能等数据出来、看见哪边差异大再临时改口——那样等于悄悄挪动了门槛。

这里有个容易绊倒初学者的地方：p 值衡量的是“证据 against H_0 的强弱”，而不是“ H_1 为真的概率”，更不是“差异有多大”。一个 tiny 的 p 值只说明“不太可能纯属巧合”，至于差异在现实里是否有意义，还得看效应量与专业判断。把这点想通，后面五花八门的 t 检验与非参数检验，其实都是同一套思想的不同化身。

5.2 显著性水平与第一、二类错误

判定“p 值小到离谱”的那条红线，叫做**显著性水平**，习惯用 α 表示，最常用的值是 0.05。它的含义朴素直白：我们允许自己在 H_0 明明为真时，却错误地把它拒之门外的风险不超过 5%。一旦 $p \leq \alpha$ ，就称结果“在 α 水平下显著”，于是拒绝 H_0 ；反之 $p > \alpha$ 则“未能拒绝 H_0 ”——请注意，是“未能拒绝”而非“接受了 H_0 ”，就像法庭上“证据不足”不等于“被告清白”。

任何判断都有走眼的可能，假设检验也不例外，且走眼分两种：

- **第一类错误** (Type I)： H_0 本为真，我们却拒绝了它。它发生的概率，恰恰就是 α 。把 α 定得越低，犯这类错的可能就越小，但代价是更难发现问题。
- **第二类错误** (Type II)： H_0 本为假，我们却没拒绝它。它发生的概率记作 β 。与 α 相反， α 压得越低， β 往往越高——太谨慎地不肯冤枉 H_0 ，就容易放过真正存在的差异。

检验功效 (power) 等于 $1 - \beta$ ，即“当 H_0 确实为假时，我们成功把它揪出来的概率”。理想状态下，我们希望 α 小而功效大；现实中二者需要权衡，而增大样本量、减少测量误差、或选用更贴合数据结构的检验，都是抬高功效的正道。

样本量在这场权衡里举足轻重。效应量既定的情况下，样本越大，标准误越小，检验功效越高，越容易把真实存在的差异辨认出来；样本太小则常导致功效不足，即便差异客观存在，也可能因 p 值卡在门槛之外而被误读为“没有差异”。这也提醒我们：同样的 p 值，出现在大样本里未必令人振奋，出现在小样本里却要谨慎——后者常常只是“证据还不够多”，而非“真的无差异”。

把两类错误放进现实，意义立刻浮现。医学筛查里，宁可多喊几次“假警报”（第一类错误）也不愿漏掉真病人；司法定罪则极力压低“冤枉好人”的概率，宁可放过某些疑犯。这些取向，本质上都是在 α 与 β 之间做取舍。

还要提醒一句：显著性 $\neq$ 重要性。p 值很小，往往只是因为样本足够大，连微乎其微的差异也能被检出；此时真正该看的是**效应量** (effect size)，它独立于样本规模，回答“差异到底有多大”。后文每一类 t 检验，我们都顺带给出效应量的线索，正是为了避免“显著却无足轻重”的误读。

5.3 单样本 t 检验

当我们手握一组观测值，又知道某个参考总体的均值，想判断“这份样本是不是来自那个总体”时，**单样本 t 检验**正合适。它的命令形态由一个 TESTVAL= 子命令触发，写法固定而简洁：

T-TEST TESTVAL=值 /VARIABLES=变量。

TESTVAL= 后面填的是那个已知的参考均值（待检验的 H_0 值），/VARIABLES= 指定要检验的变量。通用子命令如 /CRITERIA=CI(0.95) 可调整置信区间的覆盖水平，/MISSING 控制缺失值的处理方式。图形界面的入口在 Analyze $\rightarrow$ Compare Means $\rightarrow$ One-Sample T Test（界面推断，手册未逐项文档化）。

下面构造一份数据：某次考试中，往届学生的总体平均分稳定在 75 分，这届抽了 10 名学生，想看看他们的水平是否偏离了这条基准线。 H_0 为“均值等于 75”， H_1 为“均值不等于 75”。

```
DATA LIST LIST /score.
BEGIN DATA.
78
82
71
76
80
73
85
79
74
77
END DATA.
```

T-TEST TESTVAL=75 /VARIABLES=score.

PSPP 会输出一张单样本检验表，关键栏目包括样本均值、与检验值的差、t 值、自由度 df、双尾 p 值，以及均值差的 95% 置信区间。把上面这份数据的输出按栏目铺开，大致长这样：

变量	样本均值	与检验值之差	t	df	双尾 p	95% CI 下限	95% CI 上限
score	77.5	2.5	1.860	9	0.096	74.46	80.54

就上面的数据而言，样本均值为 77.5，与 75 相差 2.5；t 值约为 1.860，自由度 $df = 9$ ，双尾 p 值约为 0.096，95% 置信区间约为 [74.46, 80.54]。

解读时先看置信区间：它整体落在 75 的上方一侧，却又跨过了 75 这个点本身。对应的 p 值 0.096 略高于常用的 $\alpha = 0.05$ 门槛，因此在 5% 水平上我们**未能拒绝** H_0 ——也就是说，仅凭这 10 个分数，尚不足以断言本届学生已整体偏离往届基准。这个“差一点就显著”的案例，正是提醒读者：p 值只是连续的概率，贴着门槛的解读要格外审慎，别把 0.049 与 0.051 想成天壤之别。

另需说明，PSPP 在单样本检验中报告的 p 值默认为双尾；若研究在事前已明确只关心某一方向（如“是否高于 75”），可将双尾 p 值除以 2 作为单尾参考值，但方向必须事前确定，不能看了数据再选。

5.4 独立样本 t 检验

若想比较**两个互不相干的组**在某个连续变量上的均值，例如男女生身高、两种工艺的良率评分，就该请出**独立样本 t 检验**。它由 GROUPS= 子命令触发：

T-TEST /VARIABLES=变量 /GROUPS=分组变量(值1, 值2)。

/GROUPS= 后的括号里填分组变量的两个取值，PSPP 据此把个案切成两组再做比较。图形界面入口在 Analyze → Compare Means → Independent-Samples T Test（界面推断，手册未逐项文档化）。

这份检验最贴心的设计，是输出中**自动附带 Levene 方差齐性检验**。t 检验默认要求两组方差相当；Levene 检验正是先替你确认这一点。它给出两行 t 检验结果：第一行“假定方差齐性”，第二行“不假定方差齐性”。判读口诀很清楚——先看 Levene 的 p 值：若 $p > \alpha$ ，认为两组方差无显著差异，采用第一行；若 $p \leq \alpha$ ，方差不齐，改看第二行。

构造一组对照实验数据：实验组（group=1）与对照组（group=2）各 5 例，观测某项得分。

```
DATA LIST LIST /score group.
BEGIN DATA.
70 1
72 1
74 1
75 1
73 1
68 2
66 2
70 2
67 2
65 2
END DATA.
```

T-TEST /VARIABLES=score /GROUPS=group(1,2)。

本例 Levene 检验的 p 值约为 0.85，远大于 0.05，说明两组方差齐性成立，于是读取第一行：t 值约为 4.60， $df = 8$ ，双尾 p 值约为 0.002，两组均值差为 5.6，其 95% 置信区间约为 [2.80, 8.40]。p 远小于 0.05，拒绝 H_0 ，认为两组得分存在显著差异，且效应量 Cohen's d 约为 2.9，属大效应。易错点在于：务必让 GROUPS() 括号里的取值与数据集中分组变量的真实取值对上，否则 PSPP 会把不属于这两组的个案忽略或报错。

5.5 配对样本 t 检验

还有一种常见情形：同一批对象在接受处理前后各测一次，或一对对匹配好的个体各测一次。这时两组数据**天然成对**，前后两次的个体差异才是关注焦点，应当使用**配对样本 t 检验**，由 PAIRS= 子命令触发：

T-TEST /PAIRS=变量1 WITH 变量2 (PAIRED)。

这里有个务必上心的细节：WITH 连接的两个变量若不写 (PAIRED)，PSPP 会生成所有可能的变量配对组合；只有加上 (PAIRED)，才真正把“变量 1 的第 i 个个案”与“变量 2 的第 i 个个案”——锁死，做严格的配对比较。图形界面入口在 Analyze → Compare Means → Paired-Samples T Test（界面推断，手册未逐项文档化）。

下面用一份前后测数据演示：8 名受试者训练前的指标 pre 与训练后的指标 post。

```
DATA LIST LIST /pre post.
BEGIN DATA.
60 64
62 63
59 61
61 65
58 60
63 66
57 59
60 62
END DATA.
```

```
T-TEST /PAIRS=pre WITH post (PAIRED).
```

配对检验的实质，是把每一对的前后差（post - pre）当作一个新的样本，再做单样本 t 检验，检验这些差值的均值是否为 0。本例 8 个差值的平均约为 2.5，t 值约为 6.614，df = 7，双尾 p 值小于 0.001，差值均值的 95% 置信区间约为 [1.61, 3.39]，全程落在 0 的上方。结论明确：训练后指标显著高于训练前，效应量相当可观。若当初漏写（PAIRED），系统可能把 pre 与 post 当成两组独立变量胡乱配对，结果便失去“同一人前后对比”的意义。

5.6 非参数检验入门

t 检验虽好，却背着几项前提：数据近似正态、至少是连续定距变量、且最好两组方差齐。一旦样本量很小、分布明显偏斜、存在极端值，或者手里只是“满意/一般/不满意”这类**有序分类数据**，硬上 t 检验就不牢靠了。这时该转向**非参数检验**——它们不依赖总体的分布形状，因而更稳健，代价通常是统计功效略低。在 PSPP 里，这类方法统一收在 NPAR TESTS 命令之下。

NPAR TESTS 通过不同的子命令区分具体检验，下面逐一给出语法与适用场景。

拟合优度：/CHISQUARE。用来判断一个分类变量的频数与你预期的频数是否吻合，例如掷骰子是否公平、选民意向是否均匀。可指定取值范围与期望比例：

```
NPAR TESTS /CHISQUARE=vote(1,3) /EXPECTED=0.3,0.4,0.3.
```

/EXPECTED=EQUAL 表示期望各分类均等；也可像上面这样给出不等的期望权重。

符号检验：/SIGN。适用于配对资料，尤其当差值分布明显不对称、或数据为有序等级时。它只数“正差”与“负差”的个数，连差值大小都不依赖，因此极为稳健：

```
NPAR TESTS /SIGN=before WITH after (PAIRED).
```

Wilcoxon 配对秩检验：/WILCOXON。同样是配对资料，但它利用了差值的大小与符号、转化为秩后检验，比符号检验更敏感；代价是假定差值围绕中位数大致对称：

```
NPAR TESTS /WILCOXON=before WITH after (PAIRED).
```

Mann-Whitney 两独立组秩和检验：/MANN-WHITNEY。它是独立样本 t 检验的非参数替身，比较两组个案的秩和，对正态性没有要求。可缩写为 M-W：

```
NPAR TESTS /MANN-WHITNEY=score BY group(1,2).
```

括号里是分组变量及其两个取值；凡取值既非 g1 也非 g2 的个案会被自动忽略，这一点要留心。

沿用一组小数据感受它的用法：

```
DATA LIST LIST /score group.
BEGIN DATA.
55 1
60 1
58 1
62 1
59 2
64 2
61 2
66 2
```

END DATA.

NPART TESTS /MANN-WHITNEY=score BY group(1,2).

输出会给出两组的秩和、U 统计量及对应的 p 值；若 $p \leq \alpha$ ，便可认为两组分布位置不同。它不告诉你差了多少，只告诉你“位置是否挪动了”——这正是非参数方法克制而诚实的一面。

正态性检验：/KOLMOGOROV-SMIRNOV。用来考察某个变量是否服从指定的理论分布，最常拿来检查“数据够不够正态”，从而决定前面能不能放心用 t 检验。可缩写为 K-S，括号内声明分布类型与参数：

NPART TESTS /KOLMOGOROV-SMIRNOV (NORMAL 75 10)=score.

上面以均值 75、标准差 10 的正态分布为参照；括号里还能换作 UNIFORM、POISSON、EXPONENTIAL 等分布。若对 score 与 age 同时检验正态性，可写 /KOLMOGOROV-SMIRNOV (NORMAL 3.5 2.0)=score age.，其中每个变量套用各自的 mu、sigma。

除以上五项外，PSPP 手册还实现了 BINOMIAL、COCHRAN、FRIEDMAN、KENDALL、KRUSKAL-WALLIS、MCNEMAR、MEDIAN、RUNS 等非参数过程，覆盖二项比例、多相关样本、秩相关、多组独立比较、配对四格表、中位数与随机性等诸多场景，需要时可在 NPART TESTS 下继续探索。图形界面的非参数入口多在 Analyze → Nonparametric Tests → ...（界面推断，手册未逐项文档化）。

挑选哪一类检验，归根到底要先问三个问题：数据是独立的还是配对的？是连续定距还是有序分类？分布够不够正态、样本够不够大？把这几条理顺，t 检验与非参数检验的分工便一目了然——前者锋利却挑数据，后者温和而兜底。# 第六章 方差分析

当我们想要比较的不再是两组，而是三个乃至更多个处理组的均值是否存在差异时，t 检验已无力承担——反复两两比较不仅繁琐，更会因多次检验抬高第一类错误的概率。方差分析（Analysis of Variance，简称 ANOVA）正是为解决这一类多组均值比较问题而生的工具。它与前一章的 t 检验共享同一种思维底色：用变异的分解去衡量“组间差异”是否大到足以对抗“组内随机波动”。

6.1 方差分析的基本思想

方差分析的出发点，是把观测值围绕总均值的离差平方和（即总变异）劈成两半。其中的一半归因于不同处理组之间的系统差别，称作组间变异；另一半则来自同一组内部个案之间不可避免的随机起伏，称作组内变异。组间变异刻画的是处理因素可能带来的效应，组内变异则构成了衡量这种效应是否可信的“背景噪声”。

把两部分的离差平方和各自除以对应的自由度，就得到组间均方（MS_{between}）与组内均方（MS_{within}）。二者之比构造出 F 统计量：

$$F = MS_{\text{between}} / MS_{\text{within}}$$

如果各个组的真实均值其实并无差别，那么组间均方与组内均方都在估计同一片噪声，F 值理应游走在 1 附近；一旦处理因素确实造成了均值偏移，组间均方会被显著抬高，F 值随之偏离 1。于是检验的核心问题变成了：观测到的 F 值大到什么程度，才能让我们放心地说“这不是随机噪声造成的”。

要让这套推断逻辑站得住脚，方差分析对数据提出了三项前提假设：

- **独立性：**各个个案的观测彼此独立，一组的得分不应牵动另一组。
- **正态性：**在每个处理组内，因变量近似服从正态分布。
- **方差齐性：**各个处理组的因变量总体方差相等（即同方差）。

前两项假设在温和偏离时，方差分析的结论通常仍具稳健性；方差齐性一旦被严重破坏，尤当各组样本量又不均衡之际，F 检验的结果就会失真。本章随后的 6.4 节将专门讨论如何通过 Levene 检验审视这一前提，以及在齐性不成立时该怎么办。

回到数据本身，一个因素所取的不同取值称作“水平”（level），例如施肥处理这一因素可有 A、B、C 三个水平。方差分析所比较的，正是这些水平对应的因变量均值。单因素方差分析与线性回归实为同一族模型的两面：把分类因素编码为虚拟变量后，回归的 F 检验与 ANOVA 的 F 检验在数学上完全等价。这也解释了为何 PSPP 用一个统一的 GLM 去承载更复杂的多因素设计——它本质上就是把方差分析写进了一般线性模型的框架里。

6.2 单因素方差分析

只含一个分类自变量（因素）的方差分析，在 PSPP 中由 ONEWAY 命令承担。它专司单因素场景，能够通过子命令直接索取描述统计、方差齐性检验，以及一组事后多重比较。

图形界面下，这条分析位于菜单 Analyze → Compare Means → One-Way ANOVA（界面推断，手册未逐项文档化）。不过在数据录入稳定后，直接书写语法往往更清晰、更可复现：

```

ONEWAY yield BY treatment
  /STATISTICS=DESCRIPTIVES HOMOGENEITY
  /POSTHOC=TUKEY ALPHA(0.05).

```

其中 BY 之后的 treatment 为分类因素变量，yield 为连续型因变量；/STATISTICS=DESCRIPTIVES 输出各组均值、标准差与个案数，HOMOGENEITY 则请求 Levene 方差齐性检验；/POSTHOC=TUKEY ALPHA(0.05) 在整体 F 检验显著之后，对所有组对执行 Tukey 诚实显著差异（HSD）比较，显著性水平设为 0.05。

在正式跑出 F 值之前，稳妥的做法是先对数据做一番体检。EXAMINE 命令可针对每个处理组输出描述统计与箱线图，并附带 Shapiro-Wilk 正态性检验，帮助判断 6.1 节所列前提是否被严重违反。若正态性或独立性存疑，在跑 ANOVA 之前先考虑非参数替代或更严谨的取样设计，往往比事后补救更可靠。

下面沿用手册随附示例数据集 horticulture.sav（虚构数据，仅供教学，不可用于研究）的思路，构想一组三类施肥处理对作物产量的比较。为便于直接运行，这里改用 DATA LIST 内嵌数据：

```

DATA LIST LIST /treatment (A8) yield (F8.2).
BEGIN DATA.
A 14.2
A 15.1
A 13.8
B 17.6
B 18.3
B 16.9
C 12.4
C 13.0
C 12.1
END DATA.
VARIABLE LABELS yield '作物产量（吨/公顷）'.

```

```

ONEWAY yield BY treatment
  /STATISTICS=DESCRIPTIVES HOMOGENEITY
  /POSTHOC=TUKEY ALPHA(0.05).

```

输出结果可沿着四个层次解读：

1. **Descriptives 表**：逐一给出 A、B、C 三组的均值、标准差与样本量。若 B 组均值明显高于其余两组，便为后续推断埋下伏笔。
2. **方差齐性检验（Test of Homogeneity of Variances）**：即 Levene 统计量及其显著性。若显著性大于 0.05，可认为各组方差齐性成立，F 检验的前提得到满足；否则需警惕，参见 6.4 节。
3. **ANOVA 表**：列出组间与组内的平方和、自由度、均方，以及最终的 F 值与显著性。当显著性小于 0.05 时，可断定至少有一个组的均值与其他组不同——但 ANOVA 本身不指明究竟是哪几组有别。
4. **Tukey 多重比较表**：在整体显著的前提下，逐对比较三组。表中会标注哪些组对之间的差异达到显著，从而把“至少有一处不同”的笼统结论落实到具体的组与组之间。

6.3 双因素方差分析

当研究同时引入两个分类因素，并希望考察它们各自的主效应以及二者是否叠加出交互效应时，便进入了双因素（乃至多因素）方差分析的领地。这里必须郑重提醒一个 PSPP 的关键事实：**SPSS 习惯使用的 UNIANOVA 与 ANOVA 命令在 PSPP 中均未实现，双因素及多因素方差分析必须改走 GLM 命令**。直接书写 UNIANOVA 或 ANOVA 会在 PSPP 中报错，切勿当作可直接操作的步骤。

GLM 以 BY 引导固定因素（fixed factors），并以 /DESIGN 子命令显式声明要纳入的项，交互项用星号 * 连接。一条典型的双因素语法如下：

```

GLM 因变量 BY 固定因素1 固定因素2
  /DESIGN = 固定因素1 固定因素2 固定因素1*固定因素2.

```

沿用手册 MTBF BY factory BY environment 的分析思路——研究不同工厂（factory）与不同运行环境（environment）对设备平均无故障时间（mtbf）的影响——可这样组织命令：

```

GLM mtbf BY factory environment
  /DESIGN = factory environment factory*environment
  /METHOD = SSTYPE(3).

```

这里 `factory` 与 `environment` 均为分类因素，`/DESIGN` 同时写入两个主效应项与一个交互项 `factory*environment`。`/METHOD=SSTYPE(3)` 指定 III 型平方和，这也是 GLM 的默认设定，对不平衡设计尤为稳妥；若设计完全均衡，I、II、III 型平方和结果一致。

输出中需要重点关注两类效应：

- **主效应**：在 `factory` 这一行，我们读到工厂因素对 `mtbf` 的单独影响，它剥离了环境因素的贡献；同理，`environment` 一行反映环境因素的单独作用。显著性小于 0.05 即表明该因素的主效应存在。
- **交互效应**：`factory*environment` 一行检验两个因素是否相互牵制——例如某工厂在干燥环境下表现优异，在潮湿环境下却一落千丈。一旦交互效应显著，单纯罗列主效应便可能产生误导，此时应当绘制交互作用轮廓图，并在各环境水平内分别比较工厂间的差异。

若要衡量效应的强弱，可参考 GLM 输出的偏 η^2 方 ($\text{partial } \eta^2$) 等效量指标，它告诉我们某一个因素所解释的变异在剔除其他项之后仍占多大比重——显著性只回答“有没有”，效应量才回答“有多大”。需要说明，GLM 的固定因素应当是分类变量；若误将连续变量放入 `BY` 之后，PSPP 会按其取值层级处理，结果往往并非分析者本意。

解读交互效应最忌笼统。当 `factory*environment` 显著时，意味着“工厂的优劣取决于环境”——主效应表上的 `factory` 均值差，只是把两种环境混在一起后的平均印象，可能掩盖了真实的此消彼长。规范的后续做法是拆分 (`probe`) 交互：固定 `environment` 的某一水平，在该水平内单独比较各 `factory`；或反过来固定 `factory` 比较各 `environment`。这类分层比较俗称简单效应分析，其结论应当结合交互轮廓图的走势来陈述，而非仅凭主效应表的显著性下判断。

6.4 方差齐性检验

方差齐性（各组总体方差相等）是 F 检验赖以成立的前提之一。PSPP 在 `ONEWAY` 与 GLM 中均可通过 Levene 检验对此进行审查，二者指向同一统计量：它对“各组绝对离差围绕其组均值的离散程度是否一致”作出判断，对正态性假设不如 Bartlett 检验那般敏感，故而更为常用。

在 `ONEWAY` 中，齐性检验由 `/STATISTICS=HOMOGENEITY` 触发，输出落在名为 `Test of Homogeneity of Variances` 的表中（参见 6.2 节）。在 GLM 中，Levene 检验同样可在相应子命令下索取，其数值含义与 `ONEWAY` 完全一致，只是表头随模型表述略有差异。解读时看显著性 (`Sig.`) 一列：取值大于 0.05，说明没有足够证据推翻“方差齐”的原假设，可放心沿用标准的 F 检验；取值小于或等于 0.05，则提示至少两组方差存在显著差异。

齐性受阻之后的处理路线有三条。其一，当样本量在各组大致均衡时，方差分析对轻微不齐仍具稳健性，可谨慎报告结果并如实说明局限。其二，对因变量作对数、平方根等变换，常能压平方差随均值攀升的趋势，使齐性得以恢复后重新拟合。其三，若变换无济于事，应转向不依赖方差齐性的替代方案——例如第六章未直接覆盖的非参数单因素方法（Kruskal-Wallis 检验，对应 `NPAR TESTS`），或在 `ONEWAY` 的事后比较中选用对不齐性较宽容的 Games-Howell 法（见 6.5 节）。

实务中有个常被忽视的细节：Levene 检验本身对样本量敏感，小样本下它力不从心，容易放过真实的不齐；大样本下又过于严苛，连临床上无足轻重的微小差异也判为显著。因此显著性数字之外，还应直接观察各组标准差的比值——经验上若最大组标准差超过最小组的二倍，齐性假设便值得认真对待。

6.5 多重比较与事后检验

当整体的 F 检验告诉我们“组间均值不全相等”之后，下一个自然的问题是：究竟是哪几组彼此不同？逐对做 t 检验会放大第一类错误，因此方差分析通常配套一组受控的事后比较 (`post hoc comparisons`)。`ONEWAY` 通过 `/POSTHOC` 子命令提供丰富的选项：

```
ONEWAY yield BY treatment
      /POSTHOC=LSD TUKEY BONFERRONI SCHEFFE SIDAK GH ALPHA(0.05).
```

各方法的取向有别：

- **LSD** (Least Significant Difference)：对每对比较不做额外校正，检验最灵敏却也容易冒出假阳性，适合作为探索性筛查。
- **TUKEY** (Tukey HSD)：控制“所有组对比较家族”的误差率，均衡设计时效率尤高，是 pairwise 比较的默认首选。
- **BONFERRONI**：以简单 Bonferroni 校正收紧每对的显著性门槛，稳健而略显保守。
- **SCHEFFE**：可比较任意线性对比（不限于成对），最为保守，适合复杂的对照规划。
- **SIDAK**：基于 Sidak 不等式校正，功效通常略优于等价的 Bonferroni。
- **GH** (Games-Howell)：不对方差齐性作要求，当 Levene 检验提示齐性受阻时是理想的补充手段。

这些方法背后的共同关怀，是“家族 wise 误差率”（familywise error rate, FWER）：若对 k 个组做全部 $C(k, 2)$ 对比较，每对单独以 0.05 为门槛，累计犯至少一次第一类错误的概率会远高于 0.05。LSD 几乎不加防护，所以灵敏度最高也最易误报；TUKEY、BONFERRONI、SIDAK、SCHEFFE 则通过不同策略把这个累计概率压回 0.05 附近。选型时有个朴素准绳：组数不多且只关心成对比较，TUKEY 通常最称手；对照方案预先定好且涉及复杂线性组合，SCHEFFE 更周全；方差不齐则直接交给 GH。

ALPHA(value) 设定家族 wise 显著性水平，缺省即 0.05；可与其他方法并列书写。

至于 GLM 框架下的多重比较，PSPP 官方手册在本章节节点未给出逐项语法与输出说明，故此处依据通用统计知识作一补充：在双因素及多因素模型中，研究者往往需要在某个因素的主效应显著之后，对其各水平做 pairwise 比较，或在交互效应显著时于另一因素各水平内分层比较。其统计原理与 ONEWAY 的事后检验一脉相承——同样是在控制家族误差率的前提下，借助 Tukey、Bonferroni 等校正区分真实差异与随机起伏。实际操作时，宜先将预期比较写清于分析方案，再据手册对应节点所支持的语法落实，避免在数据窥探之后临时增补比较而损害推断的有效性。# 第七章 回归分析

回到第六章末尾那句判断：单因素方差分析把分类因素编码为虚拟变量之后，与线性回归在数学上并无二致。那一章处理的是“不同组的均值是否相等”，本章则把问题往前推一步——不再满足于比较是否不同，而是试着用一个或几个变量去预测另一个变量，并量化预测能有多准。这一族方法（相关与回归）和方差分析共享同一个理论底座，即一般线性模型（general linear model）；差别只在自变量是连续还是分类、目标是有方向地预测还是对称地度量关联。

本章先以 CORRELATIONS 探查变量间的线性联动，再用 REGRESSION 建立可预测的线性模型，最后直面 PSPP 在回归诊断上的能力边界。所用示例数据均为虚构，思路参考 PSPP 随附的 physiology.sav，仅用于教学，不可用作研究结论。

7.1 相关分析与回归分析的关系定位

相关分析与回归分析常被放在同一章讲述，却承担不同的分工。相关分析回答“两个变量是否同步变动、联动有多紧密”，它本身不区分谁预测谁；回归分析回答“已知若干变量，能否预测另一个变量、预测误差有多大”，它明确区分因变量与自变量。一句话，相关描述关系，回归把关系变成可操作的预测方程。

两者之所以能同框，根子在于它们都是一般线性模型的特例。第六章已提到，把分类因素编码为虚拟变量后，方差分析的 F 检验与回归的 F 检验在数学上完全等价；事实上，相关、回归、方差分析都建立在同一条线性代数主线上：用一组自变量的线性组合去逼近因变量，再把总变异拆成“被模型解释”和“未被解释（残差）”两部分。第六章借 GLM 统一承载多因素设计，正是因为一般线性模型把这些都收编进了同一框架。

具体而言，Pearson 相关与简单回归之间的纽带非常直接。当只有一个自变量时，回归得到的标准化系数 Beta 的绝对值恰好等于相关系数 r ；非标准化系数 B 与 r 、各自的标准差之间也存在确定换算。不过两者的取向并不相同：相关是对称的， $r(\text{height, weight})$ 与 $r(\text{weight, height})$ 完全相同，没有方向；回归是不对称的，必须事先指定哪个是自变量、哪个是因变量，得到的是“由 X 预测 Y ”的一条方程。相关只告诉你“有没有关系、有多强”，回归进一步告诉你“若 X 变动一单位， Y 平均变动多少”。

回归把“预测一个连续变量”这件事形式化，靠的是一条直线方程与一种估计准则。模型写作：

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \varepsilon$$

其中 β_0 是截距， $\beta_1 \dots \beta_k$ 是各自变量的系数， ε 是残差。估计系数的准则通常是普通最小二乘法（ordinary least squares, OLS），即让所有个案残差的平方和达到最小。这样一来，“预测”就从直觉变成了可估计、可检验、可横向比较的对象——这正是回归相对于单纯相关多出的一块能力。

实践里到底该先跑相关还是直接上回归，取决于研究问题有没有预设方向。若只想确认两个变量是否联动、并不打算由一方去预测另一方，相关足以胜任；若研究本就带着“用 X 估计 Y ”的目的，应当直接建立回归，相关至多作为前置的直观体检。二者并不互斥：先以相关窥探变量间的线性强度，再以回归给出可操作的预测方程，是常见且稳妥的工作流。

阅读本章时，有两条跨章线索值得记住。其一，相关分析呼应第四章描述统计：在盯着相关系数之前，应当先看各变量的均值与标准差（第四章的 DESCRIPTIVES），确认变量的尺度与分布是否支撑后续的线性度量。其二，回归与第六章方差分析血脉相连：两者都用 F 检验判断“模型是否显著优于仅凭均值预测”，都倚赖残差概念衡量未能解释的变异；回归里的 R^2 与 ANOVA 里的“组间变异占总变异之比”在精神上一脉相承。

7.2 相关分析 CORRELATIONS

CORRELATIONS 计算变量两两之间的 Pearson 积矩相关系数。图形界面下它位于菜单 Analyze → Correlate → Bivariate（界面推断，手册未逐项文档化）。最常用、也最清晰的做法仍是直接书写语法：

```

CORRELATIONS /VARIABLES=height weight
              /PRINT=TWOTAIL SIG
              /STATISTICS=DESCRIPTIVES.

```

/VARIABLES 之后罗列参与分析的变量，命令会输出它们之间的对称相关矩阵。若改用 /VARIABLES=v1 WITH v2 v3 的形式，则只计算 v1 与后两者之间的相关，得到的是非方阵而非完整交叉表。这一写法在只想看某个核心变量与其余变量关联时尤其省心。

/PRINT 控制检验方向与显著性呈现：可取的选项是 {TWOTAIL, ONETAIL} 与 {SIG, NOSIG}。TWOTAIL 表示双尾检验，SIG 会在 p 值低于 0.05 时把该相关高亮提示；命令默认即为 TWOTAIL 与 NOSIG（即不显示显著性，只给系数）。/STATISTICS=DESCRIPTIVES 会在相关矩阵之前附上各变量的均值、标准差与有效个案数，便于读者先确认样本规模与量纲。/MISSING 默认为 PAIRWISE（成对删除，即每一对相关只用同时有效的个案计算），也可改为 LISTWISE（整例删除，凡含任意缺失值的个案一律剔除）。成对删除能尽量保住样本，但不同相关所用的有效个案数可能不同，比较矩阵时须留意样本量一行；整例删除则保证所有系数基于同一批个案，代价是可能浪费数据。两者取舍没有绝对优劣，关键是报告时如实说明采用了哪一种。

CORRELATIONS 计算的始终是 Pearson 相关，它衡量的是两个变量的线性关系强度。系数 r 落在 -1 到 1 之间：符号指示方向，正值为同向变动、负值为反向变动；绝对值指示强度，越接近 1 线性关联越紧，接近 0 则几乎呈水平散乱。与 r 一并给出的 p 值回答“样本中观测到的关联是否可能纯粹出于偶然”——当 p 小于所选 α （通常 0.05），才可认为该相关在统计上区别于 0。

解读相关时有两个易踩的坑。第一，r 的平方（决定系数）才刻画两个变量共享的方差比例，是一个可用的效应量：r 仅为 0.5 时共享方差约 25%，中等强度的相关远非“解释了一半”。第二，也是最根本的一条——**相关不等于因果**。r 显著只说明两变量同步变化，它既不区分方向，也不能断言“是 X 导致 Y”。若要论证因果，还需实验设计或理论支撑，这已超出 CORRELATIONS 的本领。

在敲下相关命令之前，先用散点图直观确认关系形态是稳妥的习惯。GRAPH 一次只绘制一种图形，散点图这样写（菜单路径推断为 Graphs → Legacy Dialogs → Scatter/Dot，界面推断，手册未逐项文档化）：

```

GRAPH /SCATTERPLOT = height WITH weight.

```

若散点明显沿一条斜带分布，说明线性假设大致成立，Pearson r 才有意义；若呈曲线、团块或离散点阵，则 r 会低估甚至掩盖真实关系，此时应考虑变换变量或改用非线性方法。

下面构造一份虚构数据集，记录 12 个个体的身高（厘米）与体重（千克），演示相关分析：

```

DATA LIST LIST /id (A4) height (F4.0) weight (F4.0).
BEGIN DATA.
P001 172 65
P002 168 60
P003 180 75
P004 160 52
P005 175 70
P006 165 58
P007 178 72
P008 158 50
P009 170 63
P010 182 78
P011 166 57
P012 174 68
END DATA.
VARIABLE LABELS height '身高(厘米)' weight '体重(千克)'.

```

```

GRAPH /SCATTERPLOT = height WITH weight.
CORRELATIONS /VARIABLES=height weight
              /PRINT=TWOTAIL SIG
              /STATISTICS=DESCRIPTIVES.

```

结果解读要点：散点图应呈现从左下到右上的斜带；相关矩阵中 height 与 weight 的 r 通常落在 0.9 附近，且 SIG 远小于 0.05，表明身高与体重的线性关联在本样本里既强又显著。/STATISTICS=DESCRIPTIVES 输出的均值与标准差则给出变量的集中与离散概况。务必补一句：相关显著不等于因果，它只说明两变量同步变化，不能断言“长高导致变重”。

7.3 简单线性回归 REGRESSION

把“由身高预测体重”从相关推进到一条具体方程，用的就是 REGRESSION。图形界面下它位于菜单 Analyze → Regression → Linear（界面推断，手册未逐项文档化）。一元（简单）线性回归的语法结构如下：

```
REGRESSION /VARIABLES=height weight /DEPENDENT=weight
           /STATISTICS=DEFAULTS
           /SAVE=PRED RESID /METHOD=ENTER.
```

这条语法的几个要点需要逐一交代。/VARIABLES 与 /DEPENDENT 都是必填项：前者列出全部变量，后者指定因变量；凡列在 /VARIABLES 中却没有出现在 /DEPENDENT 里的变量，一律被当作自变量——本例里 height 因此成为唯一的预测变量。/STATISTICS 决定输出哪些结果块，可取值为 {ALL, DEFAULTS, R, COEFF, ANOVA, BCOV, CI[conf, TOL]}；其中 DEFAULTS 等价于同时请求 R、COEFF、ANOVA，恰好覆盖模型解读所需的三块核心输出。/ORIGIN 与 /NOORIGIN 控制是否强制回归线经过原点，默认是 /NOORIGIN，即保留截距项；除非有充分的理论依据要求方程过零点，否则保留默认，切勿随手改为 /ORIGIN 而误删截距。若需要未标准化系数的方差—协方差矩阵，可在 /STATISTICS 追加 BCOV，它给出各系数估计之间的协方差结构，对理解系数估计的相互联系也有帮助。最后，/SAVE=PRED RESID 把预测值（新变量 PRED1）与残差（新变量 RES1）写回活动数据集，为 7.5 节的诊断做准备；多个变量时按先后次序编号。/METHOD=ENTER 表示将所有自变量一次性强制纳入，不做逐步筛选。

沿用 7.2 的数据集，直接运行上面这段语法即可。结果由三张表承载，解读时各有侧重：

- **模型汇总 (Model Summary)**：给出 R（复相关系数，一元情形下等于 $|r|$ ）与 R^2 （决定系数）， R^2 衡量因变量的变异中有多少比例被模型解释，是回归里最常用的效应量；该表还给出估计标准误（Std. Error of the Estimate），即残差标准差的估计，刻画预测值偏离真实值的典型幅度，该值越小预测越紧凑。
- **ANOVA 表**：报告整体 F 检验，其 SIG 回答“模型整体上是否显著优于仅凭均值预测”。当 SIG 远小于 0.05，可认为回归方程确有解释力。
- **系数表 (Coefficients)**：核心所在，给出常数（截距）与自变量的非标准化系数 B、标准化系数 Beta、标准误、t 值与 SIG。以 体重 = $B_0 + B_1 \times$ 身高 为例， B_0 为截距、 B_1 为斜率，含义是身高每变动一单位、体重平均变动多少千克；SIG 判断该自变量的回归系数是否显著区别于 0。一元情形下 Beta 的绝对值恰好等于相关系数 r。

解读要点：若 R^2 接近 0.8，意味着身高独自解释了体重约八成的变异，决定系数这一效应量相当可观；ANOVA 表的 F 检验 SIG 应远小于 0.05，确认模型整体有效；系数表中 height 的 B 通常在 0.7~0.9 区间，可表述为“身高每增加 1 厘米，体重平均增加约 B 千克”，其 SIG 小于 0.05 说明该斜率在统计上显著。此时 PRED1 与 RES1 已写入数据集，可在数据视图查看每个个案的预测值与残差。

7.4 多元回归与模型解读

现实问题很少只受单一因素支配。多元回归把两个及以上自变量同时放进模型，估计在控制其他变量之后，每个自变量的独立贡献。语法与一元模型几乎一致，只需在 /VARIABLES 增加变量；若要顺带做共线性诊断，可在 /STATISTICS 追加 TOL：

```
REGRESSION /VARIABLES=height weight age /DEPENDENT=weight
           /STATISTICS=DEFAULTS TOL
           /SAVE=PRED RESID /METHOD=ENTER.
```

这里 age 作为新增自变量进入模型。需要留意，TOL 仅在同时请求 COEFF 时才有效；由于 DEFAULTS 已经包含 COEFF，故 TOL 能正常产出。PSPP 不直接输出方差膨胀因子（VIF），但 $VIF = 1 / TOL$ ，拿到容忍度后手算即可。

多元回归的输出沿用 7.3 的三张表，但解读角度要补三件事。

系数表在多元场景里尤为重要。非标准化系数 B 表示在控制其他自变量后，该自变量每变动一单位、因变量平均变动多少；它的实际单位仍是因变量的量纲，便于直接解释。标准化系数 Beta 则把所有变量先标准化到同一量纲后再估计，因而可在不同自变量之间比较“谁的影响相对更大”——比如比较身高（厘米）与年龄（岁）对体重的相对贡献时，Beta 比 B 更有可比性。每行仍附标准误、t 值与 SIG，分别用于判断单个系数是否显著区别于 0。

模型汇总在多元场景里出现两个决定系数： R^2 与调整 R^2 （Adjusted R Square）。 R^2 随自变量增多只会升不降，哪怕新增的变量毫无解释力， R^2 也会被它“虚抬”；调整 R^2 则对自变量的个数施加了惩罚，每多引入一个变量都要付出自由度代价，因此更适合在模型之间做比较，也更诚实地反映模型的简约性。把调整 R^2 的公式拆开看，它的惩罚项来自样本量 n 与自变量个数 p 的比值——当 n 相对 p 很大时，两种 R^2 相差无几；当模型趋于饱和（p 逼近 n）时，调整 R^2 会明显低于 R^2 ，甚至变为负，提示模型在“过拟合”边缘。当某个自变量的 SIG 大于

0.05，意味着在已纳入其他变量的模型中，它的独立线性贡献不足以与随机波动区分开，此时不宜引用其斜率作结论，应考虑剔除或重新审视变量定义。

ANOVA 表汇报的是整个回归（所有自变量合在一起）的显著性，其 F 检验回答“模型整体是否优于仅凭均值预测”。它不针对单个自变量，单个自变量的显著性要看系数表的 SIG。

共线性是多元回归特有的隐患。当自变量之间彼此高度相关，各自的系数估计会变得不稳定、标准误膨胀、符号难以解释。容忍度（TOL）反映某个自变量不能被其余自变量线性解释的比例，数值等于 1 减去该变量对其余自变量回归的决定系数；容忍度越低，共线性越严重。经验上容忍度低于 0.1（保守些也会看 0.2）往往提示问题，其倒数 VIF 超过 10（宽松些看 5）通常视为共线性信号。两者一体两面，报告时择一即可，但初学者同时列出更便于核对。值得注意的是，共线性损害的是“解释”，却不必然损害“预测”——即便系数摇摆不定，模型对样本内 Y 的整体拟合仍可能不错，因此不能仅凭 R^2 高就推断每个自变量都可靠。

7.5 回归诊断与限制

线性回归的有效性依赖若干前提：残差近似正态、方差齐性（残差的散布不随预测值变化）、自变量与因变量之间确为线性关系，以及各案观测相互独立。按理说，这些前提该由回归过程一并报告，让使用者一次看清模型是否可靠。

然而必须如实说明一个关键事实：**PSPP 的 REGRESSION 并未提供 /SCATTERPLOT、/RESIDUALS、/CASE-WISE、/OUTLIERS 等专用诊断子命令，也没有 Durbin-Watson 统计量、Cook 距离的直接输出**。这部分在 PSPP 手册中并未逐项覆盖，属于通用统计知识，而非 PSPP 特有的可操作步骤。因此，任何把残差诊断写成“在 PSPP 里点几下即可完成”的描述都是不准确的；在 PSPP 当前版本中，这类诊断必须手工处理。

PSPP 留给我们的唯一内置出口是 /SAVE=RESID（常配合 PRED），把残差 RES1 与预测值 PRED1 落回活动数据集，之后再通用过程自行检视。下面给出一条完整、可在 PSPP 中直接运行的示例，仍以 7.2 的身高-体重数据演示：先拟合简单回归并写出残差，再用 EXAMINE 检查残差的正态性。

```
DATA LIST LIST /id (A4) height (F4.0) weight (F4.0).
BEGIN DATA.
P001 172 65
P002 168 60
P003 180 75
P004 160 52
P005 175 70
P006 165 58
P007 178 72
P008 158 50
P009 170 63
P010 182 78
P011 166 57
P012 174 68
END DATA.
VARIABLE LABELS height '身高(厘米)' weight '体重(千克)'.
```

* 拟合简单回归，并将残差与预测值写回数据集

```
REGRESSION /VARIABLES=height weight /DEPENDENT=weight
           /STATISTICS=DEFAULTS
           /SAVE=PRED RESID /METHOD=ENTER.
```

* 检视残差正态性：直方图 + 正态概率图（自动附带 Shapiro-Wilk 检验）

```
EXAMINE RES1 /PLOT=HISTOGRAM NPLOT /STATISTICS=DESCRIPTIVES.
```

* 检视方差齐性与线性：残差对预测值散点，应呈围绕 0 线的无规律横向带

```
GRAPH /SCATTERPLOT = PRED1 WITH RES1.
```

按上面的语法跑完后，可作如下解读：

- **残差正态性**：EXAMINE 的 /PLOT=HISTOGRAM 给出残差直方图，NPLOT 给出正态概率图；只要请求了图形，PSPP 会自动执行 Shapiro-Wilk 正态性检验。若 Shapiro-Wilk 的 p 值大于 α （如 0.05），通常不拒绝残差正态的假定，可认为正态性前提基本满足。直方图若明显偏斜或出现厚尾，则提示正态性可能受损。
- **方差齐性与线性**：落在 GRAPH /SCATTERPLOT = PRED1 WITH RES1 这张残差对预测值的散点图上。若点是围绕 0 线的随机云团、上下宽度基本恒定，则方差齐性、线性两项假设皆可接受；若出现喇叭口（一

侧散开)、弧形弯曲或明显斜带,则分别暗示异方差、非线性或遗漏变量。

下面三条概念属于通用统计知识([手册未覆盖,说明为通用统计知识]),PSPP 不提供直接输出,列在此处供读者判断模型健康度:

- **残差独立性**:理想情况下,一个个案的残差不应预示着另一个个案的残差,尤其对时间序列数据要警惕相邻残差正相关。侦测它的 Durbin-Watson 统计量在 PSPP 中没有现成输出,需借 /SAVE=RESID 取出残差后用其他工具手算。
- **异方差**:残差的方差应不随预测值水平变化;若散点呈喇叭口,小预测值处紧凑、大预测值处发散,则违背方差齐性。可考虑对因变量取对数等变换,或改用对异方差稳健的估计。
- **多重共线性**:已在 7.4 节讨论,用 TOL/VIF 窥探;它只影响系数估计的稳定性,不直接影响模型整体的预测能力。

一旦图形发出警示,应回到数据层面处置,而这部分在 PSPP 里同样要手工完成:异方差可考虑对因变量取对数等变换(COMPUTE 生成新变量后重新拟合),或改用对异方差稳健的估计思路;非线性可尝试加入自变量的平方项、交互项(COMPUTE 生成后纳入 /VARIABLES);怀疑遗漏变量则补充测量或换用 GLM 纳入更多预测变量。PSPP 的 REGRESSION 仅提供建模与 /SAVE 出口,变换、稳健处理与更复杂的设定都需在回归前后用 COMPUTE、GLM 等另行完成,不能指望一条 REGRESSION 命令把诊断与补救打包做完。

需要特别强调两个子命令的生效条件,以免误用:CI(置信区间)仅在同时选定 COEFF 时才有效,单独写 CI 而不带 COEFF 不会产出区间;TOL 同样仅在 COEFF 被选中的前提下有效。也就是说,若想得到系数的 95% 置信区间,应写作:

```
REGRESSION /VARIABLES=height weight age /DEPENDENT=weight
           /STATISTICS=COEFF CI(0.95) TOL
           /SAVE=PRED RESID /METHOD=ENTER.
```

把回归结果讲给非专业读者,关键是把系数翻译成人话,并交代清楚“能说什么、不能说什么”。一份清晰的报告通常先说关联是否存在,再说预测关系(“身高每增高 1 厘米,体重平均增加约 B 千克”),最后说解释力(R^2 回答了百分之几的变异被解释)。决定系数 R^2 是直接讲“百分之几的变动能被解释”最直观的效应量,比抛出一个相关系数更易被记住;系数的可靠性则由各自的 SIG 与(如已请求)95% 置信区间支撑。

无论相关还是回归,输出的都只是统计关联,不能自动升级为因果断言。若要论证因果,还需实验设计或理论支撑,这超出 CORRELATIONS 与 REGRESSION 本身的本领。最后,诚实地写明诊断结论——残差是否近似正态、方差是否齐性,以及 PSPP 未能直接给出的 Durbin-Watson 与 Cook 距离如何以 /SAVE=RESID 配合其他工具补做——能让一份回归报告经得起推敲。# 第八章 图表制作

把一份数据集跑完描述统计、假设检验、方差分析与回归,得到的终究是一串统计量:均值、显著性、回归系数、残差。这些数字本身是对的,但要让读者在几秒内抓住数据的轮廓,文字与表格远不如一张图来得直接。图表的作用,正在于把抽象的统计结果还原成肉眼可判的形状:分布是偏是对称、两组均值差了多少、两个连续变量是否同步起伏。本章沿着前七章的分析脉络,说明在 PSPP 里如何把数据画成散点图、直方图、条形图、箱线图,以及哪些图在 PSPP 当前版本里画不出来、又该往哪里绕。

需要提前建立的一个基本认知是:PSPP 的作图能力是“够用”而非“全能”。它不追求 SPSS 那种完整的图表引擎,而是把最常用的几种图形拆成几条清晰、可复现的命令。理解这一点,便能坦然接受本章列举的诸多限制,而不会在找不到某个菜单时误以为是自己操作失误。

8.1 图表命令总览

PSPP 里画图,主要有两条路径。

第一条是 GRAPH 命令。图形界面下它位于菜单 Graphs → Legacy Dialogs → ...之下(界面推断,手册未逐项文档化),子菜单再按散点图、直方图、条形图细分为 Scatter/Dot、Histogram、Bar 等项。GRAPH 是 PSPP 专门负责“一次画一张图”的命令,它把最常见的三种图形——散点图、直方图、条形图——都收在一个命令名下,靠不同的子命令区分。

第二条路径,是借用其他分析命令内嵌的图形子命令。前面几章已经反复遇到:FREQUENCIES 可以顺带画直方图与条形图(第四章),CROSSTABS 能画条形图(第四章),EXAMINE 能画箱线图、直方图与正态概率图(第四章)。这些图形不是独立命令,而是附着在主分析之上、随输出一并产生的副产品。本章会逐一说明哪些图走 GRAPH、哪些图只能借道其他命令。

关于 GRAPH,有一个约束必须一开始就说清:一次调用只能画一种图。GRAPH 的子命令只有 HISTOGRAM、SCATTERPLOT、BAR 三种可选,且三者互斥——你在一条 GRAPH 语句里写了 /SCATTERPLOT 就不能再写 /HISTOGRAM。想把散点图和直方图都画出来,就得写两条 GRAPH 命令,各画各的。这与 SPSS 里某些可一次堆叠多张图的对话框不同,是 PSPP 的语法事实,后面 8.6 节还会再次强调。

* 一条 GRAPH 只能画一种图，以下两条命令各司其职
GRAPH /SCATTERPLOT = height WITH weight.
GRAPH /HISTOGRAM = weight.

理解了这个总览，下面三节就按图的类型逐个展开。

8.2 散点图 GRAPH /SCATTERPLOT

散点图用来呈现两个连续变量之间的关系形态，是相关分析与回归之前最该先看的一张图（呼应第七章 7.1、7.2 节）。在 GRAPH 里，散点图由 /SCATTERPLOT 子命令承载，基本语法为：

```
GRAPH /SCATTERPLOT[(BIVARIATE)] = var1 WITH var2 [BY var3].
```

var1 与 var2 是横、纵坐标上的两个连续变量，二者之间用 WITH 连接；BIVARIATE 关键字可写可不写，指明这是“双变量”散点图，省略时 PSPP 也按双变量处理。BY var3 是可选的分组项：一旦写上，PSPP 会按 var3 的不同取值给点着色，把原本混杂的一团点按类别拆成几组，便于一眼看出不同类别在关系上的差异。BY 引入的 var3 通常是分类变量（例如性别），它只改变着色与分组，并不改变横纵坐标本身的含义。

沿用第七章 7.2 的身高—体重数据，画一张基础的散点图：

```
DATA LIST LIST /id (A4) height (F4.0) weight (F4.0) gender (F1.0).  
BEGIN DATA.  
P001 172 65 1  
P002 168 60 2  
P003 180 75 1  
P004 160 52 2  
P005 175 70 1  
P006 165 58 2  
P007 178 72 1  
P008 158 50 2  
P009 170 63 1  
P010 182 78 1  
P011 166 57 2  
P012 174 68 2  
END DATA.  
VARIABLE LABELS height '身高(厘米)' weight '体重(千克)' gender '性别'.  
VALUE LABELS gender 1 '男' 2 '女'.
```

```
GRAPH /SCATTERPLOT = height WITH weight BY gender.
```

这里 height 在横轴、weight 在纵轴，BY gender 使男性与女性的点以不同颜色呈现。输出查看器中，这张图会出现在本次语法运行的图形区；若点的整体由左下向右上斜向铺开，说明身高越高体重越重，线性关系成立，这时第七章算出的 Pearson 相关系数才有意义。若 BY gender 之后发现两类点的斜率明显不同，则提示性别可能在身高—体重关系中起调节作用，单看全样本的相关就会掩盖这种结构，需在分组后分别考察。需要提醒：散点图本身只呈现形态，不输出任何显著性数字，它扮演的是“先看一眼再决定怎么分析”的侦察角色。图上的每一个点对应数据集里的一个个案，横纵位置由该个案在两个变量上的取值决定，因此点的疏密也隐含了个案的分布密度。

读懂一张散点图，至少要看三件事。第一看走向：点若沿一条斜带铺开，说明两变量存在线性关联，斜率方向即相关系数符号；若带子近乎水平，则关联微弱，此时第七章算出的相关系数会接近 0。第二看形状：若点的轨迹弯成弧线或呈团块状，说明关系并非线性，Pearson 相关系数会低估甚至掩盖真实联系，这时应考虑变换变量或改用非线性模型，而非硬套线性回归。第三看离群：个别远远甩在带子之外的点，可能是一个录入错误，也可能是一个真正特殊的个案——它会在不点明的情况下拉高或拉低相关系数，借助第四章 EXAMINE /ID= 的思路定位到具体个案编号，再决定保留还是核查，是稳健的做法。当 BY var3 引入分组着色后，还应比较各组点的走向是否一致：若男性点的斜率与女性点明显不同，全样本的相关系数其实只是把两种结构混在一起的平均印象，这时分组分别跑相关或回归才更准确。

菜单路径为 Graphs → Legacy Dialogs → Scatter/Dot（界面推断，手册未逐项文档化）。

8.3 直方图 GRAPH /HISTOGRAM

直方图把一个连续变量的取值切进等宽区间（箱），用柱子的高度表示每个区间内落了多少个个案，用来观察单变量的分布形状：是否对称、是否偏态、是否有双峰。在 PSPP 里，直方图有不止一种画法，但 GRAPH 提供的

是最直接的一种：

```
GRAPH /HISTOGRAM[(NORMAL)] = var.
```

等号右边只能写一个变量——直方图描述的是单个连续变量的分布，写两个变量会报错。NORMAL 关键字可选，一旦附上，PSPP 会在直方图之上叠加一条理论正态曲线，方便肉眼比对“数据分布离正态分布还差多远”。这与第四章 4.2 节提到的 FREQUENCIES /HISTOGRAM=NORMAL 思路一致，只是前者从 FREQUENCIES 走、后者从 GRAPH 走。

值得专门记一笔的是：直方图在 PSPP 里有三种不同的“出身”，分箱算法各不相同——

- GRAPH /HISTOGRAM：按 GRAPH 自身的分箱策略绘制；
- EXAMINE /PLOT=HISTOGRAM：采用 Sturges 算法决定箱数（第四章 4.5 节已述及）；
- FREQUENCIES /HISTOGRAM：采用 Freedman-Diaconis 算法决定箱数（第四章 4.2 节提及）。

Sturges 与 Freedman-Diaconis 是统计上两种经典的箱宽确定法，前者对样本量较敏感、后者对异常值更稳健。同一个变量，走不同命令得到的直方图在箱子数量与边界上可能略有差别，但分布的整体形状应当一致；若差别大到结论改变，本就说明分布不稳定，需谨慎对待。Sturges 公式的箱数大致随样本量对数增长，样本量小时箱子偏少、容易把真实的多峰结构抹平；Freedman-Diaconis 则用四分位距来定箱宽，对极端值不敏感，在存在离群点时往往给出更忠实的形态。实务上若两种画法给出的形状相互矛盾，应优先参考 Freedman-Diaconis（即 FREQUENCIES 那条），并回头检查是否有异常个案在作怪。

另一个务必记住的易错点（第四章 4.2 节已点出，这里再次强调）：FREQUENCIES /HISTOGRAM 对字符串变量不绘制直方图。直方图依赖连续取值的等距分箱，字符串变量没有这种数值间距，因此遇到字符串变量时 PSPP 会静默跳过直方图子命令。对分类变量想要可视化，应改用 /BARCHART（见 8.4 节），而非硬上直方图。

读懂直方图，重点不在柱子的绝对高度，而在柱子的轮廓。若轮廓大致对称、中间高两边低呈钟形，且叠加的 NORMAL 曲线与柱顶贴合，可初步判断该变量近似正态，第四章 4.5 节提到的 Shapiro-Wilk 检验通常也不拒绝正态假设；若右侧拖出明显长尾（正偏态），均值会大于中位数，此时依赖均值与标准差的描述（第四章 4.3 节）固然可用，但若要做 t 检验之类按正态假设推导的推断，就该警惕或考虑变换。出现两个分立的峰则提示数据可能由两个子群体混成，应当考虑用 BY 分组变量拆开再看（呼应第六章按因素水平分别考察的思路）。直方图与箱线图（8.5 节）是观察单变量分布最互补的一对：直方图看整体轮廓，箱线图看四分位与极端值，二者结合比单看其一更稳妥。

* 体重直方图，并叠加正态曲线

```
GRAPH /HISTOGRAM(NORMAL) = weight.
```

* 同一变量的另外两种画法（算法不同）

```
EXAMINE weight /PLOT=HISTOGRAM.
```

```
FREQUENCIES /VARIABLES=weight /HISTOGRAM.
```

输出查看器中，直方图以连续柱子呈现。若柱子大致对称、钟形，且叠加的正态曲线与柱顶贴合良好，可初步判断该变量近似正态；若明显向右或向左拖出长尾，则是偏态，呼应第四章关于“偏态数据该走哪条推断路线”的讨论。菜单路径为 Graphs → Legacy Dialogs → Histogram（界面推断，手册未逐项文档化）。

8.4 条形图 GRAPH /BAR

条形图与直方图外形相近，但用途不同：直方图面向连续变量的分布，条形图面向分类变量的计数或汇总。在 GRAPH 里，条形图由 /BAR 子命令承载，语法结构如下：

```
GRAPH /BAR = {summary-function(var1) | count-function} BY var2 [BY var3].
```

这里有两种填法。其一是“汇总函数 + 分类变量”：先对一个连续变量 var1 套用汇总函数，再 BY 一个分类变量 var2 分出各组。可用的汇总函数有 SUM（求和）、MEAN（均值）、MAXIMUM（最大值）、MINIMUM（最小值）。例如 /BAR = MEAN(income) BY city 表示：按城市分组，画出每个城市收入的均值条。其二是“计数函数”：直接写 COUNT、PCT（百分比）、CUFREQ（累积频次）、CUPCT（累积百分比）之一，此时不再需要 var1，PSPP 自动数每个类别出现了多少次。例如 /BAR = COUNT BY city 画出各城市个案数的条形图。

BY var3 是可选的第二个分类变量。一旦写上，条形图从“单组并排”升级为“簇状条图”（clustered bar chart）：在每个 var2 的类别下，再按 var3 拆出若干根紧挨着的柱子，用颜色区分。这对于第六章方差分析里“按因素水平比较均值”、第七章回归里“按分组看预测值”的呈现都很实用。

* 簇状条图：按城市分组，再看各城市内不同性别的收入均值

```
GRAPH /BAR = MEAN(income) BY city BY sex.
```

* 简单计数条图：各城市个案数

GRAPH /BAR = COUNT BY city.

第一条命令会画出以城市为横轴、柱高为收入均值的条形图，而同一城市内不同性别以不同颜色并排成簇，方便直接比较“同城市下男女收入差距”。解读时看柱高与颜色对照：若某城市男女两色高度相差悬殊，提示该城市内性别与收入可能有关联——这恰好呼应第六章按因素水平比较均值、第七章按分组看关系的思路，但条形图只呈现差异大小，要下“是否显著”的结论仍需回到 ONEWAY、GLM 或 T-TEST。

关于汇总函数与计数函数，有两点值得说明。其一是选哪个汇总函数要看变量的性质：MEAN 适合看“平均水平”（如各城市收入均值），SUM 适合看“总量”（如各区域销售额合计），MAXIMUM/MINIMUM 则适合看极值（如各地区最高气温）。它们都要求 var1 是连续变量，因为对分类变量求均值没有意义。其二是计数函数族各自的用途：COUNT 给出每类个案数，对应频率表的频次；PCT 给出每类占总数的百分比，对应有有效百分比；CUFREQ 与 CUPCT 是累积版本，自上而下把频次或百分比累加起来，对有序分类变量（如满意度等级）才有解读价值，能读出“落在某等级及以下的比例”。当使用计数函数时，写法里不再出现 var1，直接 GRAPH /BAR = COUNT BY city 即可，PSPP 自行数出各类出现次数。

簇状条图（两个 BY）与简单条图（单个 BY）在解读上有一个微妙差别：簇状图里“同一簇内不同颜色的高度差”是组内比较，而“不同簇之间同色柱的高度差”是组间比较。仍以 MEAN(income) BY city BY sex 为例，男色柱在城市间的高低变化，反映“男性收入是否随城市变动”；同一城市内男女两色的高低差，反映“该城市内性别收入差距”。把这两种比较混为一谈，是读图时最常见的误读，应在陈述结论前先想清自己要比的是哪一层。

条形图还有两条“旁门”可走，适合在已有的分析命令里顺手出图：

- FREQUENCIES /BARCHART：对分类变量画频次条形图（第四章 4.2 节用法）；
- CROSSTABS /BARCHART：在交叉表分析里为每个行类别画条形图（第四章 4.4 节用法）。

二者与 GRAPH /BAR 的区别在于，它们依附于频率表或交叉表，图形随主表一并输出；GRAPH /BAR 则是独立的作图命令，语法更自由，能直接指定 MEAN、SUM 等汇总函数。菜单路径为 Graphs → Legacy Dialogs → Bar（界面推断，手册未逐项文档化）。

8.5 其他图表路径

前四节覆盖了 GRAPH 的三种图与若干内嵌图形，但还有几类常见图表需要专门的命令路径，且其中有的 PSPP 根本不支持。逐一说明如下。

饼图 (Pie Chart)。必须郑重写明：PSPP 的 GRAPH 命令本身没有饼图子命令，想在 PSPP 里画饼图，唯一的途径是 FREQUENCIES /PIECHART。

FREQUENCIES /VARIABLES=gender /PIECHART。

上面这条命令会为 gender 画一张饼图，每类的扇区面积对应其频次占比。切勿尝试在 GRAPH 下寻找 /PIECHART——它不存在，那样写会报错。这条限制与前面散点图、直方图、条形图“都收在 GRAPH 名下”的印象形成反差，专门点出以免读者在 GRAPH 里反复试探。饼图擅长表现“整体中各部分的占比”，当类别超过四五类时，扇区过多会难以分辨，此时换成 8.4 节的条形图反而更清楚；饼图也不宜用于表现精确数值比较，它只适合传达大致构成。菜单路径为 Analyze → Descriptive Statistics → Frequencies → Charts（界面推断，手册未逐项文档化）。

箱线图 (Boxplot)。走 EXAMINE，用 /PLOT=BOXPLOT 触发（第四章 4.5 节详述）。箱线图用五数概括（最小值、下四分位、中位数、上四分位、最大值）呈现分布，并把超出 1.5 倍四分位距的点标为可疑极端值，是探查异常个案与组间差异形态的利器。

EXAMINE weight BY gender /PLOT=BOXPLOT。

读箱线图时，箱子覆盖中间 50% 的个案（下四分位到上四分位），箱内横线是中位数；须线延伸至 1.5 倍四分位距内的最远点，超出者以独立点标出，即为可疑极端值。若同时 BY gender，则男女各得一个箱子，可直接比较中位数高低、箱子长短（离散程度）以及须线外点的多少——这与第六章方差分析里“按因素水平比较”的关切完全一致：箱子中段错位越大、重叠越少，组间差异往往越值得做正式检验。箱线图还能暴露偏态：若箱子明显偏向须上或下须，说明该组分布不对称，与直方图读出的偏态应相互印证。

正态概率图 (Normal Probability Plot, NPLOT)。同样走 EXAMINE，用 /PLOT=NPLOT 触发。它把样本分位数对理论正态分位数作图，若点大致落在一条直线上，支持“数据近似正态”的判断；配合第七章 7.4 节对回归残差的正态性检视尤为常用。

EXAMINE RES1 /PLOT=NPLOT。

正态概率图与直方图、Shapiro-Wilk 检验是观察正态性的三重保险：直方图看轮廓是否钟形，NPLOT 看点的共线程度，检验给一个量化的 p 值。三者中只要有一处强烈反对正态，就不宜把依赖正态假定的推断结论说得太

满；第七章 7.4 节正是借助 EXAMINE /PLOT=HISTOGRAM NPLOT 来核查回归残差的正态性，这条路径在本章得到完整交代。

需要补充：EXAMINE 只要在 /PLOT 里请求了 BOXPLOT、HISTOGRAM 或 NPLOT 任意一种图形，PSPP 就会自动附带 Shapiro-Wilk 正态性检验（第四章 4.5 节已说明），权重数据须为整数、累计个案数落在 3 到 5000 之间检验才给出。这几条“非 GRAPH”的作图路径，恰恰是 PSPP 探索性分析的主力，与散点图、条形图互为补充。

8.6 限制与导出

图表这一章若不把“不能做什么”讲清楚，读者很容易在软件里空耗。下面把 PSPP 当前版本在作图上的边界如实列出。

茎叶图不可用。 PSPP 未实现 STEMLEAF 命令，想要以文本方式同时看到频数分布与数值形态的茎叶图，在 PSPP 里画不出来。替代方案是改用 EXAMINE /PLOT=HISTOGRAM 看分布、或 FREQUENCIES 看频次表。这一点第四章 4.5 节末尾也已提醒过。

原始 GPL 自定义作图不可用。 PSPP 未实现 GGRAPH、IGRAPH、XGRAPH 这几条承载原始图形语法（GPL）的命令。这意味着不能用 GPL 语句去自由定义坐标轴、图层、配色或复合图形——GRAPH 命令提供的散点图、直方图、条形图三种模板，就是 PSPP 在自定义作图一端的全部家底。凡需要超出这三种模板的图形（例如小提琴图、热力图、带拟合曲线的散点），PSPP 当前不支持，须把数据导出到其他环境绘制。

GRAPH 单调用单图。回到 8.1 节的强调：一条 GRAPH 语句只能含 HISTOGRAM、SCATTERPLOT、BAR 三者之一，想凑一组图就得写多条命令。把“画多张图”当成一条命令的选项，在 PSPP 里不成立。

图表随输出生成，整体可导出。无论走 GRAPH 还是走其他命令内嵌图形，图都作为输出的一部分生成在输出查看器中，与表格、文字混排在一起。整个输出可一次性导出为 PDF、PostScript、SVG、PNG、HTML 等格式（第二章 2.1 节提到的输出格式同样适用于含图的输出）；命令行下的 pspp-output 工具支持 convert 操作，把 .pspp 输出文件转成上述格式之一（此点手册未逐项覆盖，说明为通用界面/工具知识，请以你实际安装的版本为准）。需注意，手册未详述输出查看器内“双击图形进入编辑”这类交互步骤——这部分属于通用界面知识，并非 PSPP 手册明示的操作流程，实际能否编辑、编辑到什么程度，请以你运行的 PSPPIRE 表现为准，本书不将其描述为确定的 PSPP 操作步骤。

把上面的限制汇总成一句话：在 PSPP 里画图，能用的是 GRAPH 的三种模板、以及 FREQUENCIES/CROSSTABS/EXAMINE 内嵌的饼图、条形图、箱线图、正态概率图；画不出来的是茎叶图与任何 GPL 自定义图形。遇到后者，最务实的做法是把当前数据集用 SAVE 存成 .sav，再导入支持更丰富图形的环境继续，而非在 PSPP 里反复尝试不存在的命令。

为便于查阅，下表把本章涉及的每种图与其对应的命令路径一并列出，星号表示该项为 PSPP 当前不支持：

图形	推荐命令	备注
散点图	GRAPH /SCATTERPLOT	支持 BY 分组着色
直方图	GRAPH /HISTOGRAM	可叠 NORMAL 正态曲线
条形图（汇总/计数）	GRAPH /BAR	支持单 BY 与簇状双 BY
条形图（频次）	FREQUENCIES /BARChart、CROSSTABS /BARChart	依附主表输出
饼图	FREQUENCIES /PIEChart	GRAPH 无饼图子命令
箱线图	EXAMINE /PLOT=BOXPLOT	自动附 Shapiro-Wilk 检验
正态概率图	EXAMINE /PLOT=NPLOT	用于正态性核查
茎叶图	—	* PSPP 未实现 STEMLEAF
GPL 自定义图	—	* PSPP 未实现 GGRAPH/IGRAPH/XGRAPH

导出图形的具体流程，在图形界面下通常是在输出查看器里把整份输出另存为目标格式；命令行下则是用 pspp-output 的 convert 子命令把 .pspp 输出文件转为 PDF、SVG、PNG 等（此点手册未逐项覆盖，说明为通用界面/工具知识，请以你实际安装的版本为准）。需要重申：手册未详述输出查看器内“双击图形进入编辑”这类交互步骤，这部分属于通用界面知识，并非 PSPP 手册明示的操作流程，实际能否编辑、编辑到什么程度，请以你运行的 PSPPIRE 表现为准，本书不将其描述为确定的 PSPP 操作步骤。若要把图单独取出来嵌进报告，最稳妥的办法是导出整份输出为 PDF 或 SVG 后再从中裁剪，而非依赖查看器内的就地编辑。

作为全书的收尾，图表制作把“数据到结论”的最后一公里补完：第四章的描述统计让我们读懂分布，第五章与第六章的检验让我们判断差异，第七章的回归让我们建立预测，而本章的散点图、直方图、条形图与箱线图，则

把这些结论变成一眼可辨的形状。需要反复记住的是，图是呈现与侦察的工具，不是检验本身——显著性、效应量、方差齐性这些判断，仍要回到对应的命令去求得；图的价值在于让数字的结论更可信、也更易于传达给读者。
附录

附录 A • PSPP 命令速查表

下表在提纲“命令 → 菜单路径速查映射”基础上扩展为三列：命令、语法功能、关键子命令或注意点。其中【手册明示】表示手册中确实出现过的菜单/对话框引用；【界面推断】表示按 PSPP/SPSS 通用界面结构推断，其依据为通用界面知识，手册未逐项文档化，实际菜单名称可能随版本略有差异。PSPP 命令统一以英文句点，结尾 (data> 提示符期间不要输入句点)。下表覆盖本书正文涉及的主要命令，未穷尽全部子命令；正文中已逐项展开的语法模板可与此表对照查阅。

PSPP 命令	语法功能	关键子命令或注意点
pspp / psppire	启动命令行 / 图形界面	【推断】经终端或开始菜单启动；pspp 为文本界面，psppire 为图形界面
DATA LIST + BEGIN DATA	定义变量并录入数据	【推断】对应 Variable View + Data View；BEGIN DATA/END DATA 须配对，END DATA 独占一行
GET DATA /TYPE=ODS	导入 OpenDocument/Excel 表格	【推断】File → Import Data；/TYPE 须为首个，/VARIABLES 须放最后；ASSUMEDSTRWIDTH 易截断长文本，建议显式指定
GET DATA /TYPE=TXT	导入 CSV/定界文本	【推断】File → Import Data；/DELIMITERS= 用 \t 表示制表符；遗漏 /FIRSTCASE=2 会把表头当数据读入
IMPORT	读取系统/便携文件	【推断】File → Open；仅读取.sav 等 PSPP 文件，不能直接读 Excel/CSV，后者须用 GET DATA
SORT CASES	排序个案	【手册明示】Data → Sort Cases；(D) 降序、(A) 升序（默认）；只改变活动数据集，不改原.sav
SPLIT FILE	拆分文件分组输出	【推断】Data → Split File；LAYERED 合并于一张表、SEPARATE 各组独立表；持续生效至 SPLIT FILE OFF。
SELECT IF / FILTER	选择 / 过滤个案	【推断】Data → Select Cases；SELECT IF 永久删除未选中个案，FILTER 仅隐藏、可 FILTER OFF 恢复
COMPUTE	计算新变量	【推断】Transform → Compute Variable；数值目标变量可自动新建，字符串目标变量须先以 STRING 声明
RECODE	重新编码	【推断】Transform → Recode；THRU 含端点，ELSE 须置于末组；省略 INTO 则就地改写
MISSING VALUES	定义缺失值	【推断】Variable View → Missing；数值至多 3 个离散值或一个范围；用户缺失默认在多数过程中被排除
VARIABLE LABELS / VALUE LABELS	变量标签 / 值标签	【推断】Variable View；VALUE LABELS 会清空已有值标签，追加请用 ADD VALUE LABELS
FREQUENCIES	频率统计与图表	【推断】Analyze → Descriptive Statistics → Frequencies；/HISTOGRAM、/PIECHART、/BARChart；对字符串变量不画直方图

PSPP 命令	语法功能	关键子命令或注意点
DESCRIPTIVES	描述统计与 Z 分数	【推断】Analyze → Descriptive Statistics → Descriptives ; /SAVE 写出 Z 分数新变量 (如 Zheight)
EXAMINE	探索性分析与箱线/正态图	【推断】Analyze → Descriptive Statistics → Explore ; / PLOT=BOXPLOT NPLOT HISTOGRAM ; 请求图形时自动做 Shapiro-Wilk 检验
CROSSTABS	交叉表与 χ^2 检验	【推断】Analyze → Descriptive Statistics → Crosstabs ; / STATISTICS=CHISQ 含 Pearson χ^2 、似然比、Fisher 精确等
MEANS	分组均值	【推断】Analyze → Compare Means → Means ; / CELLS=MEAN,STDDEV,SUM,MIN,MAX, ...
T-TEST	t 检验 (单样本/独立/配对)	【推断】Analyze → Compare Means → (One/Independent/ Paired) Samples T Test ; 由 TESTVAL=/GROUPS=/PAIRS= 触发 ; 独立样本自动含 Levene 方差齐性检验
NPART TESTS	非参数检验	【推断】Analyze → Nonparametric Tests → ... ; / CHISQUARE、/SIGN、/ WILCOXON、/MANN-WHITNEY、/ KOLMOGOROV-SMIRNOV
ONEWAY	单因素 ANOVA	【推断】Analyze → Compare Means → One-Way ANOVA ; 仅处理单因素 , /POSTHOC=TUKEY 等 , / STATISTICS=HOMOGENEITY 做 Levene
GLM	析因 (双/多因素) ANOVA	【推断】Analyze → General Linear Model → Univariate ; PSPP 中双因素须走 GLM ; / DESIGN= 用 * 连接交互项
CORRELATIONS	Pearson 相关	【推断】Analyze → Correlate → Bivariate ; /PRINT=TWOTAIL SIG ; /MISSING=PAIRWISE (默认)
REGRESSION	线性 / 多元回归	【推断】Analyze → Regression → Linear ; /DEPENDENT= 必填 ; /SAVE=PRED RESID ; 缺乏 / SCATTERPLOT 等诊断子命令
GRAPH /SCATTERPLOT	散点图	【推断】Graphs → Legacy Dialogs → Scatter/Dot ; 一次调用只能画一种图
GRAPH /HISTOGRAM	直方图	【推断】Graphs → Legacy Dialogs → Histogram ; (NORMAL) 叠加正态曲线 ; 仅接受单一变量
GRAPH /BAR	条形图	【推断】Graphs → Legacy Dialogs → Bar ; 第二分类变量产生簇状条图

PSPP 命令	语法功能	关键子命令或注意点
FREQUENCIES /PIECHART	饼图（唯一途径）	【推断】Analyze → Descriptive Statistics → Frequencies → Charts；GRAPH 本身无饼图子命令，饼图只能走 FREQUENCIES

PSPP 当前未实现的过程

PSPP 并非 SPSS 的完整克隆，部分 SPSS 过程在 PSPP 中尚未实现。双因素或多因素方差分析不能依赖 ANOVA 或 UNIANOVA（二者均未实现），应改用 GLM 并在 /DESIGN 中写明交互项（如 a*b）。原始 GPL 自定义作图命令 GGRAPH、IGRAPH、XGRAPH 均不可用；茎叶图命令 STEMLEAF 不可用；SPSS 式的多格式导入命令 GET TRANSLATE 亦不可用。此外，手册还列出 MANOVA、MULT RESPONSE、CURVEFIT、PLOT 等同样未实现。涉及上述过程时，应避免在教程中描述成 PSPP 可直接完成的操作，必要时应提示读者改用替代命令或手工处理，并明确说明“PSPP 当前不支持”。

附录 B • 常用统计术语中英对照

以下术语在本书正文与 PSPP 对话框中频繁出现，统一对照如下，便于读者在英文界面与中文资料之间切换。

中文术语	英文术语
变量	variable
个案	case
数据集	dataset
变量标签	variable label
值标签	value label
缺失值	missing value
均值	mean
标准差	standard deviation
方差	variance
中位数	median
众数	mode
偏度	skewness
峰度	kurtosis
显著性	significance
p 值	p-value
置信区间	confidence interval
效应量	effect size
相关系数	correlation coefficient
决定系数	coefficient of determination
残差	residual
方差齐性	homogeneity of variance
t 检验	t-test
F 检验	F-test
χ^2 检验	chi-square test
回归	regression
相关	correlation
频数 / 频率	frequency
直方图	histogram
散点图	scatterplot
箱线图	boxplot
条形图	bar chart
交叉表	crosstabulation (crosstab)
自变量	independent variable
因变量	dependent variable
分类变量	categorical variable
连续变量	continuous variable
名义 / 有序 / 标度	nominal / ordinal / scale

用法提示：在 PSPP 语法窗口中，命令、子命令与变量名均为英文标识符，须保持原样，不可汉化；但在对话框标签、菜单与本书说明中常以中文呈现。读者在中文操作系统下阅读英文界面时，可借助本表快速对应对话框里的中文标签与底层英文术语。部分术语（如 nominal / ordinal / scale）同时出现在 Variable View 的“度量标准”列，建议与 VARIABLE LEVEL 命令对照理解，以免在分组或图形选项中混淆变量角色。

附录 C • 练习数据与素材说明

本书各章的示例数据均为作者为演示语法而虚构的虚构数据，仅用于说明操作步骤与输出解读，**不可用于任何真实研究或论文结论**。读者在练习时请始终将其视为教学素材，不要对数值本身做统计推断或外推。

GNU PSPP 官方手册随附了若干示例数据集，通常安装后位于 /usr/local/share/pspp/examples 目录，包括：

- physiology.sav：生理测量类示例（如身高、体温等）；
- personnel.sav：人事/员工类示例（如部门、职级等）；
- repairs.sav：设备维修记录类示例（如故障时间、维修时长等）；
- horticulture.sav：园艺/栽培类示例（如产量、处理分组等）。

这些文件同样是手册作者虚构的演示数据，仅用于熟悉命令，并非真实观测。读者可通过图形界面 File → Open 打开它们，或在语法中先用 GET DATA/IMPORT 读入后进行跟练。

若读者希望自建练习数据表，建议先在设计阶段确定字段，再录入或导入。一份典型的练习数据表可包含如下字段：

- 一个可作为个案标识的编号字段（如 id，numeric）；
- 1~2 个分组/分类变量（如 group、sex，建议定义值标签，例如 0= 女性、1= 男性）；
- 2~3 个连续型测量变量（如 height、weight、score，numeric，保留适当小数位）；
- 如需练习缺失值处理，可预留一个会用特殊值（如 999）标记的字段，并配套 MISSING VALUES 定义。

自建数据可在电子表格软件中先存为 ODS 或 CSV，再用 GET DATA 导入。导入 ODS 的语法要点：

```
GET DATA /TYPE=ODS /FILE='file.ods'  
          /SHEET=NAME 'Sheet1'  
          /CELLRANGE=FULL  
          /READNAMES=ON  
          /ASSUMEDSTRWIDTH=32.
```

导入 CSV/定界文本时改用 /TYPE=TXT，并以 /DELIMITERS= 指定分隔符（制表符用 \t），用 /FIRSTCASE=2 跳过表头；/VARIABLES= 必须放在最后，并显式声明各列类型与宽度，以避免长文本被截断或表头误读为数据。

需要特别注意区域设置带来的两个常见隐患。其一，在部分语言环境（locale）下，数值小数点分隔符为逗号，录入 12,5 可能被误读；教学与练习建议采用英文 locale，或在格式中显式指定 DOT8.3 等后缀以固定小数点为 .. 其二，字符串宽度默认偏窄，导入含长文本的列时务必显式设置 ASSUMEDSTRWIDTH，否则内容会被截断。

附录 D • 进阶学习资源

GNU PSPP 是自由软件，其权威资料均以官方发布为准。建议读者将以下资源作为长期参考：

- **官方网站与手册**：GNU PSPP 项目主页提供程序下载、版本说明与完整手册（Texinfo/HTML/PDF 等格式）。手册按命令分节点组织，是核查语法、子命令与缺省值的唯一权威来源。
- **许可说明**：PSPP 程序本身以 GNU GPL（GNU General Public License）发布；其文档以 GFDL（GNU Free Documentation License）发布。读者可在遵守许可条款的前提下自由使用、修改与再分发。
- **社区与常见问题**：PSPP 的用户邮件列表、发行版打包渠道与项目缺陷跟踪系统汇集了常见问题（FAQ）与版本动态。遇到界面或命令行为差异时，优先比对所装版本与官方手册。

本书内容基于 PSPP 2.0.1 左右版本编写，所引命令、子命令与缺省值以该版本官方手册为据。读者可在 pspp 文本界面启动时或 psppire 的关于对话框中查看具体版本号；命令行为与手册节点编号均可能随版本变化。需特别强调：PSPP 官方明确其仍处于“work in progress”（持续开发）状态，新版本可能增补命令、子命令或修正既有行为。**所有命令的精确写法与可用性，最终请以读者所安装版本对应的官方手册为准**；若手册与本书表述出现分歧，以官方手册为准。对尚未实现的过程（见附录 A），请勿期待在现有版本中直接可用。发现疑似缺陷时，可先在官方缺陷跟踪系统检索是否已有报告，再决定是否提交新报告，并附上可复现的语法与数据样例，以便维护者定位。